

UNIVERSIDADE FEDERAL DO CEARÁ

DEPARTAMENTO DE COMPUTAÇÃO

LogIA

Aprendizagem de Máquina Probabilística

César Lincoln Cavalcante Mattos

2026

Agenda

1. Classificação binária
2. Regressão logística binária
3. Regressão logística multiclasse
4. Regressão logística via algoritmo IRLS
5. Regressão logística Bayesiana - Aproximação de Laplace
6. Tópicos adicionais
7. Referências

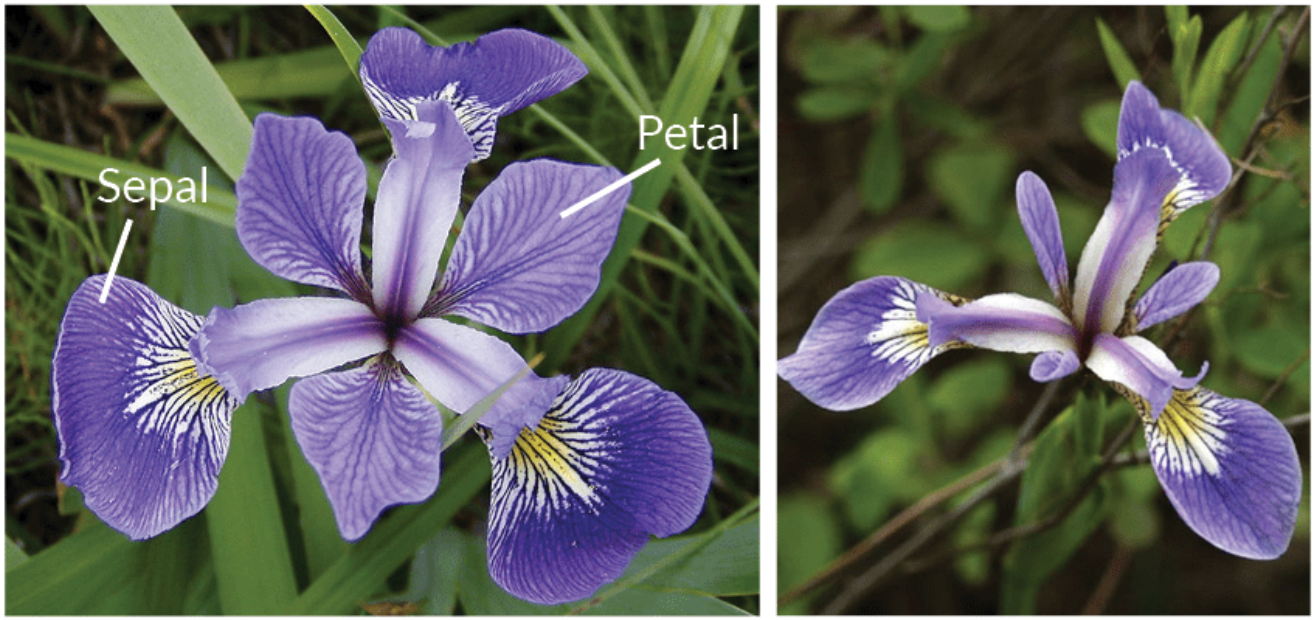
Classificação

Tarefa de classificação

Relaciona vetores de entrada a um número finito de rótulos/categorias/classes de saída.

- **Classificação binária**: Somente duas classes (sim/não, positivo/negativo, gato/cachorro, etc.)
- **Classificação multiclasse**: Mais de duas classes (dígitos, letras, raças de cachorro, marcas de carro, etc.)

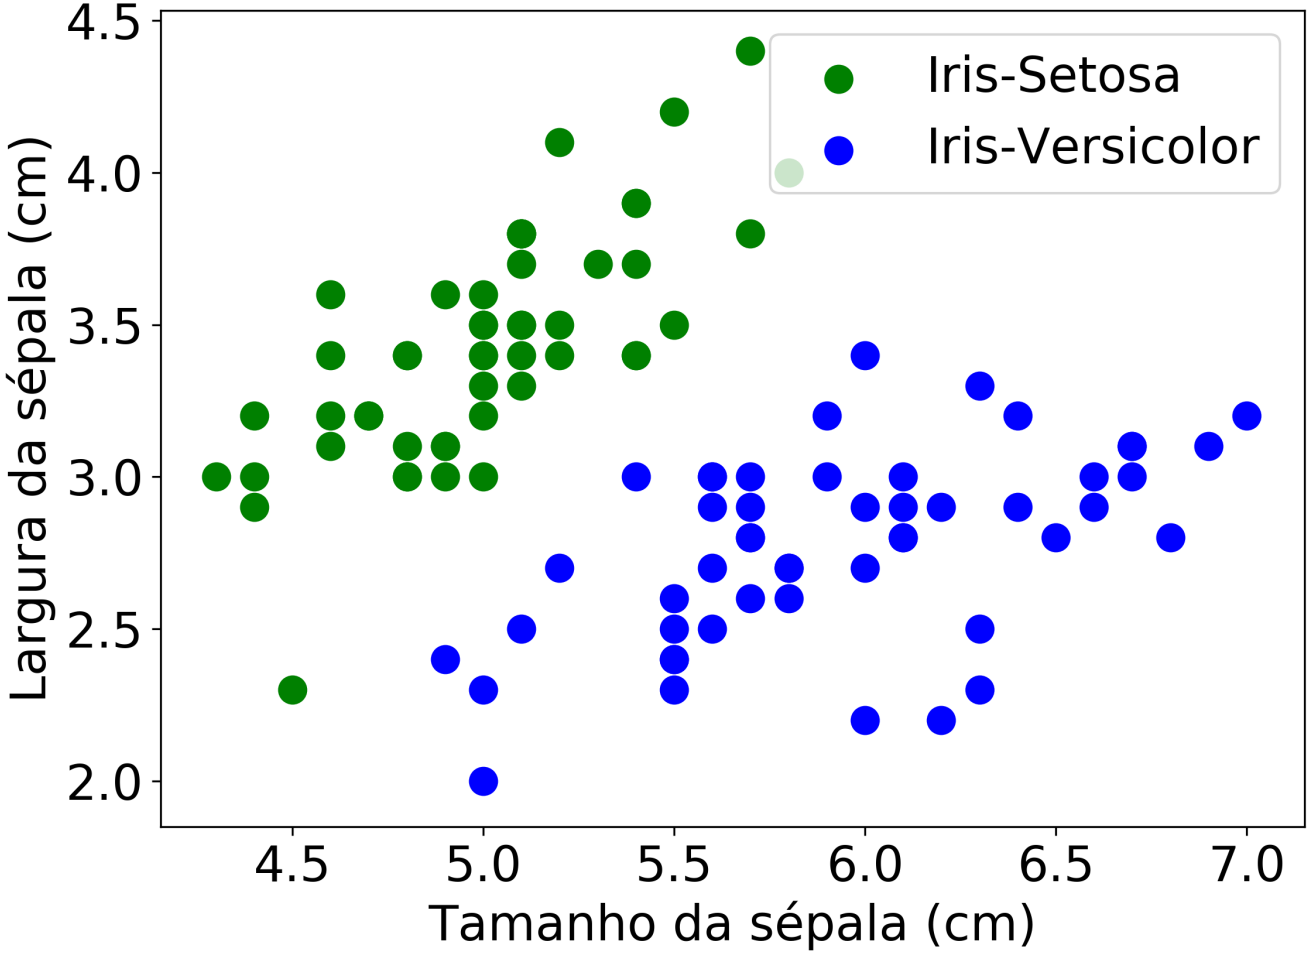
Classificação binária



Iris Versicolor **Iris Setosa**

- **Problema**: Como classificar automaticamente flores da espécie íris entre Setosa e Versicolor a partir de medidas de suas sépalas?

Classificação binária



- **Ideia**: Podemos utilizar um modelo de regressão linear nessa tarefa de classificação?

Classificação binária

- Convertemos as saídas categóricas (“setosa” ou “versicolor”) em números: -1 ou 1.

Classificação binária

- Convertemos as saídas categóricas ("setosa" ou "versicolor") em números: -1 ou 1.
- **Problema**: O modelo $\hat{y}_i = \mathbf{w}^\top \mathbf{x}_i$ retorna valores reais.

Classificação binária

- Convertemos as saídas categóricas ("setosa" ou "versicolor") em números: -1 ou 1.
- **Problema**: O modelo $\hat{y}_i = \mathbf{w}^\top \mathbf{x}_i$ retorna valores reais.
- **Ideia**: Modificar a saída para $\hat{y}_i = \text{sign}(\mathbf{w}^\top \mathbf{x}_i)$, em que:

$$\text{sign}(\mathbf{w}^\top \mathbf{x}_i) = \begin{cases} -1 & \text{, se } \mathbf{w}^\top \mathbf{x}_i < 0 \\ 1 & \text{, se } \mathbf{w}^\top \mathbf{x}_i \geq 0 \end{cases}.$$

Classificação binária

- Convertemos as saídas categóricas ("setosa" ou "versicolor") em números: -1 ou 1.
- **Problema**: O modelo $\hat{y}_i = \mathbf{w}^\top \mathbf{x}_i$ retorna valores reais.
- **Ideia**: Modificar a saída para $\hat{y}_i = \text{sign}(\mathbf{w}^\top \mathbf{x}_i)$, em que:

$$\text{sign}(\mathbf{w}^\top \mathbf{x}_i) = \begin{cases} -1 & \text{, se } \mathbf{w}^\top \mathbf{x}_i < 0 \\ 1 & \text{, se } \mathbf{w}^\top \mathbf{x}_i \geq 0 \end{cases}.$$

- **Problema**: Como modificar a regra de atualização dos parâmetros, dado que a função $\text{sign}(\cdot)$ não é diferenciável?

Classificação binária

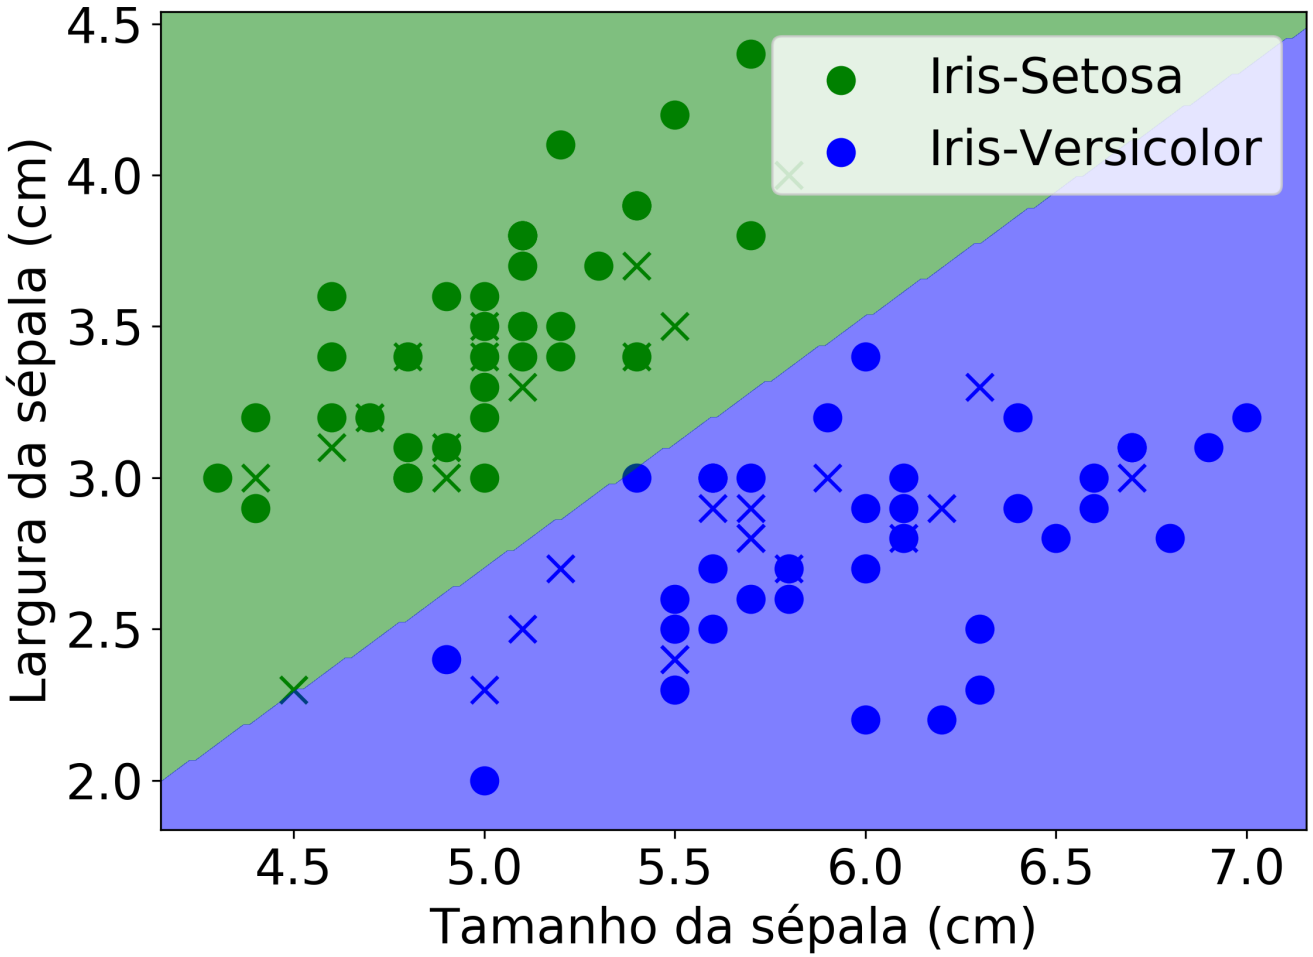
- Convertemos as saídas categóricas ("setosa" ou "versicolor") em números: -1 ou 1.
- **Problema**: O modelo $\hat{y}_i = \mathbf{w}^\top \mathbf{x}_i$ retorna valores reais.
- **Ideia**: Modificar a saída para $\hat{y}_i = \text{sign}(\mathbf{w}^\top \mathbf{x}_i)$, em que:

$$\text{sign}(\mathbf{w}^\top \mathbf{x}_i) = \begin{cases} -1 & , \text{se } \mathbf{w}^\top \mathbf{x}_i < 0 \\ 1 & , \text{se } \mathbf{w}^\top \mathbf{x}_i \geq 0 \end{cases} .$$

- **Problema**: Como modificar a regra de atualização dos parâmetros, dado que a função $\text{sign}(\cdot)$ não é diferenciável?
- **Ideia**: Vamos usar a função $\text{sign}(\cdot)$ somente na predição do modelo.

Classificação binária

- Solução via OLS: $\mathbf{w} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$
- Classificação binária (70% para treinamento e 30% para teste):



Agenda

1. Classificação binária
2. Regressão logística binária
3. Regressão logística multiclasse
4. Regressão logística via algoritmo IRLS
5. Regressão logística Bayesiana - Aproximação de Laplace
6. Tópicos adicionais
7. Referências

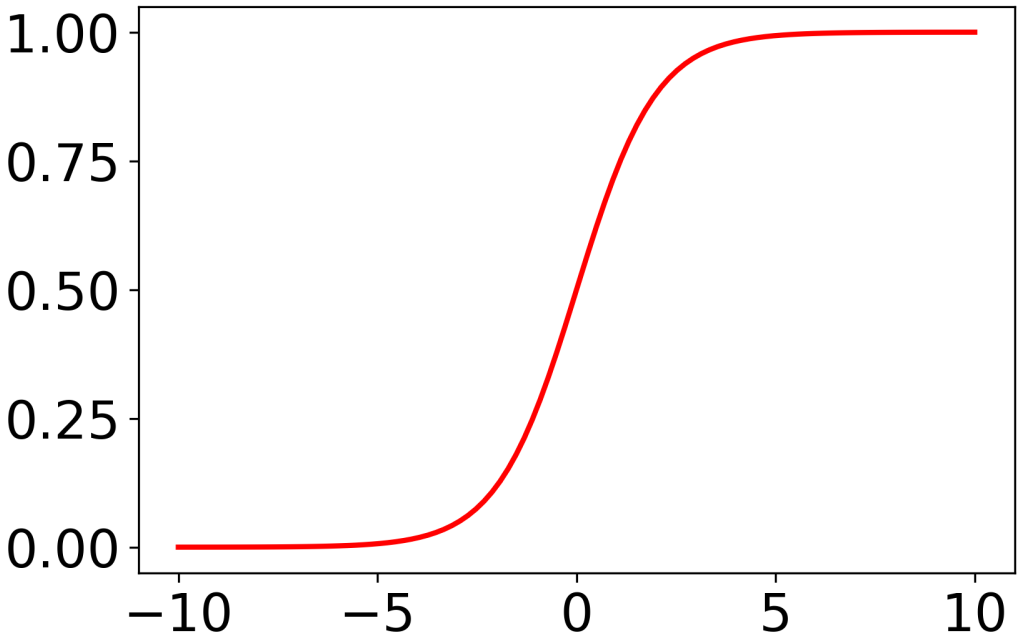
Classificação binária

- **Ideia**: Trocar a função sign$(\cdot)$ por uma função diferenciável entre 0 e 1.

Classificação binária

- **Ideia**: Trocar a função sign$(\cdot)$ por uma função diferenciável entre 0 e 1.
- **Função logística (sigmóide)**:

$$\sigma(z) = \frac{1}{1 + \exp(-z)}.$$



Classificação binária

Regressão logística

- Apesar do nome, é um método de **classificação**.
- Usa uma **função logística** na saída do modelo linear:

$$\hat{y}_i = \sigma(\mathbf{w}^\top \mathbf{x}_i), \quad \sigma(z) = \frac{1}{1 + \exp(-z)}.$$

- A função logística é definida no intervalo $[0, 1]$, possuindo interpretação probabilística.
- $\sigma(z)$ é facilmente **diferenciável**:

$$\frac{\mathrm{d}\sigma(z)}{\mathrm{d}z} = \sigma(z)(1 - \sigma(z)).$$

Regressão logística binária

- **Problema**: Como modelar probabilisticamente os dados a partir da função logística?

Regressão logística binária

- **Problema**: Como modelar probabilisticamente os dados a partir da função logística?

Distribuição de Bernoulli

- Seja uma moeda potencialmente injusta (cara (1) e coroa (0)):

$$P(y = 1|q) = q,$$
$$P(y = 0|q) = 1 - q.$$

- A Distribuição de Bernoulli é então definida por:

$$p(y|q) = q^y(1 - q)^{1-y}.$$

Regressão logística binária

- **Problema**: Como modelar probabilisticamente os dados a partir da função logística?

Verossimilhança de Bernoulli

- Considerando duas classes, 0 e 1, temos:

$$P(y = 1|\mathbf{x}, \mathbf{w}) = \sigma(\mathbf{w}^\top \mathbf{x}),$$
$$P(y = 0|\mathbf{x}, \mathbf{w}) = 1 - \sigma(\mathbf{w}^\top \mathbf{x}).$$

- A verossimilhança de Bernoulli é então definida por:

$$p(y|\mathbf{x}, \mathbf{w}) = \sigma(\mathbf{w}^\top \mathbf{x})^y (1 - \sigma(\mathbf{w}^\top \mathbf{x}))^{1-y}.$$

Regressão logística binária

- **Problema**: Qual será a nova função custo?

Regressão logística binária

- **Problema**: Qual será a nova função custo?
- **Ideia**: Escolher o negativo da **log-verossimilhança**:

$$\mathcal{J}(\mathbf{w}) = -\log p(\mathbf{y}|\mathbf{X}, \mathbf{w})$$

$$\mathcal{J}(\mathbf{w}) = -\log \prod_{i=1}^{N} p(y_i|\mathbf{x}_i, \mathbf{w})$$

$$\mathcal{J}(\mathbf{w}) = -\log \prod_{i=1}^{N} \sigma(\mathbf{w}^\top \mathbf{x}_i)^{y_i} (1 - \sigma(\mathbf{w}^\top \mathbf{x}_i))^{1-y_i}$$

$$\mathcal{J}(\mathbf{w}) = -\sum_{i=1}^{N} \left[y_i \log \sigma(\mathbf{w}^\top \mathbf{x}_i) + (1 - y_i) \log(1 - \sigma(\mathbf{w}^\top \mathbf{x}_i)) \right].$$

Regressão logística binária

Cross entropy loss

- Definida por:

$$\mathcal{J}(\mathbf{w}) = -\frac{1}{N}\sum_{i=1}^{N}\left[y_i \log \sigma(\mathbf{w}^\top \mathbf{x}_i) + (1-y_i)\log(1-\sigma(\mathbf{w}^\top \mathbf{x}_i))\right].$$

- Precisamos calcular o gradiente da função custo para atualizar os parâmetros do modelo:

$$\mathbf{w} \leftarrow \mathbf{w} - \alpha \frac{\partial \mathcal{J}(\mathbf{w})}{\partial \mathbf{w}}.$$

Regressão logística binária

- Derivando em relação a $\mathbf{w}$, temos:

$$\mathcal{J}(\mathbf{w}) = -\frac{1}{N}\sum_{i=1}^{N}\left[y_i \log \sigma(\mathbf{w}^\top \mathbf{x}_i) + (1-y_i)\log(1-\sigma(\mathbf{w}^\top \mathbf{x}_i))\right],$$

$$\begin{aligned}
\frac{\partial \mathcal{J}(\mathbf{w})}{\partial \mathbf{w}} &= -\frac{1}{N}\sum_{i=1}^{N}\left[y_i \frac{1}{\sigma(\mathbf{w}^\top \mathbf{x}_i)}\frac{\partial \sigma(\mathbf{w}^\top \mathbf{x}_i)}{\partial \mathbf{w}} - (1-y_i)\frac{1}{1-\sigma(\mathbf{w}^\top \mathbf{x}_i)}\frac{\partial \sigma(\mathbf{w}^\top \mathbf{x}_i)}{\partial \mathbf{w}}\right] \\
&= -\frac{1}{N}\sum_{i=1}^{N}\left[y_i \frac{\sigma(\mathbf{w}^\top \mathbf{x}_i)(1-\sigma(\mathbf{w}^\top \mathbf{x}_i))}{\sigma(\mathbf{w}^\top \mathbf{x}_i)}\mathbf{x}_i - (1-y_i)\frac{\sigma(\mathbf{w}^\top \mathbf{x}_i)(1-\sigma(\mathbf{w}^\top \mathbf{x}_i))}{1-\sigma(\mathbf{w}^\top \mathbf{x}_i)}\mathbf{x}_i\right] \\
&= -\frac{1}{N}\sum_{i=1}^{N}\left[y_i(1-\sigma(\mathbf{w}^\top \mathbf{x}_i))\mathbf{x}_i - (1-y_i)\sigma(\mathbf{w}^\top \mathbf{x}_i)\mathbf{x}_i\right] \\
&= -\frac{1}{N}\sum_{i=1}^{N}\left[y_i\mathbf{x}_i - y_i\sigma(\mathbf{w}^\top \mathbf{x}_i)\mathbf{x}_i - \sigma(\mathbf{w}^\top \mathbf{x}_i)\mathbf{x}_i + y_i\sigma(\mathbf{w}^\top \mathbf{x}_i)\mathbf{x}_i\right] \\
&= -\frac{1}{N}\sum_{i=1}^{N}(y_i - \sigma(\mathbf{w}^\top \mathbf{x}_i))\mathbf{x}_i \\
&= -\frac{1}{N}\sum_{i=1}^{N} e_i \mathbf{x}_i.
\end{aligned}$$

Regressão logística binária

- Com o gradiente $\frac{\partial \mathcal{J}(\mathbf{w})}{\partial \mathbf{w}}$, atualizamos o modelo via GD ou SGD.

Gradiente Descendente (GD)

- Regra de atualização:

$$\mathbf{w}(t) = \mathbf{w}(t-1) + \alpha \frac{1}{N} \sum_{i=1}^{N} e_i(t-1)\mathbf{x}_i$$

Gradiente Descendente Estocástico (SGD)

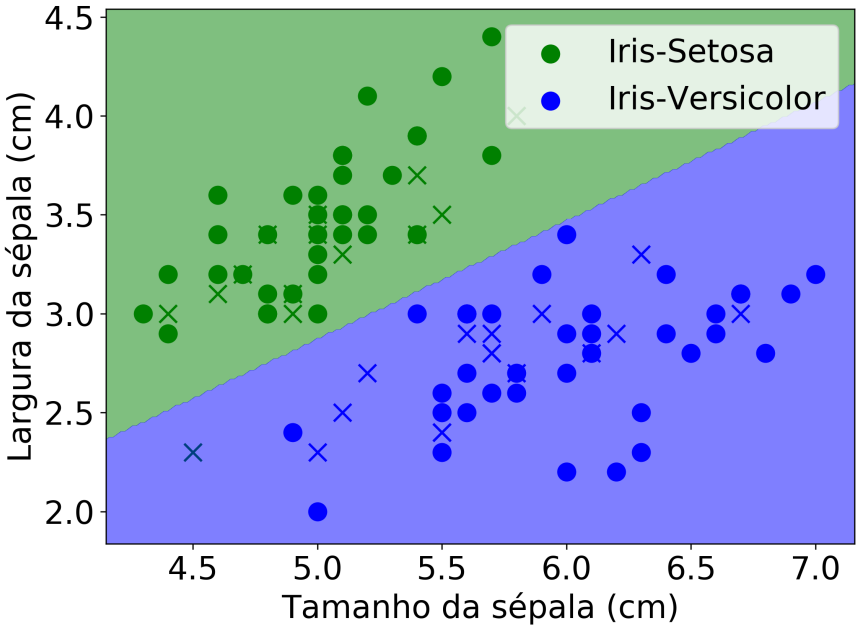
- Regra de atualização:

$$\mathbf{w}(t) = \mathbf{w}(t-1) + \alpha e_i(t-1)\mathbf{x}_i$$

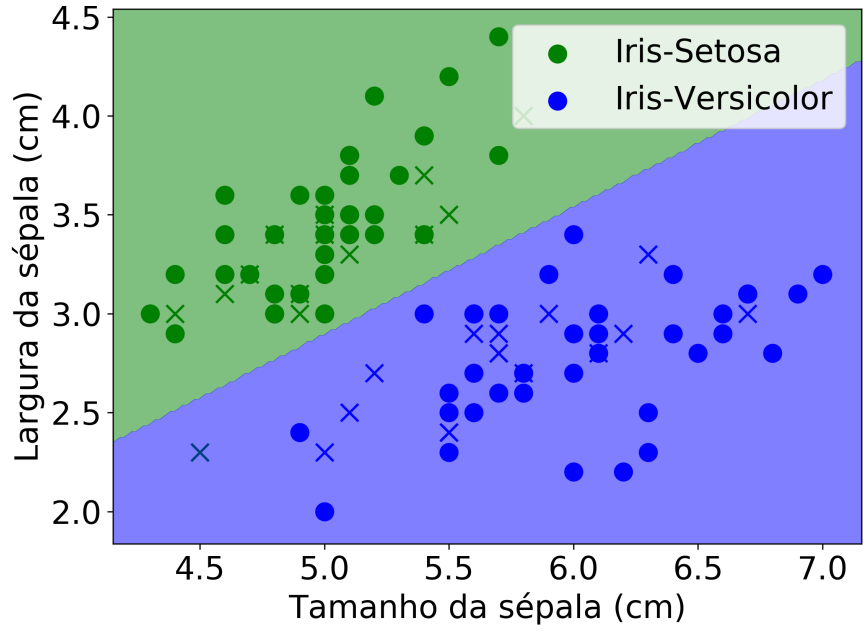
- Lembrando que na regressão logística temos:

$$e_i(t) = y_i - \sigma(\mathbf{w}(t)^\top \mathbf{x}_i)$$

Exemplo de classificação (dados separáveis linearmente)



Regressão logística via GD



Regressão logística via SGD

Regressão logística binária

- De onde vem a função logística?

Regressão logística binária

- De onde vem a função logística?
- Seja a probabilidade da classe 1 ocorrer $p \in [0, 1]$.
- Seja ainda os **odds** (razão das chances) $\frac{p}{1-p} \in [0, \infty]$.
- Consideramos a obtenção do **log-odds** $\log \frac{p}{1-p} \in [-\infty, \infty]$.

Regressão logística binária

- De onde vem a função logística?
- Seja a probabilidade da classe 1 ocorrer $p \in [0, 1]$.
- Seja ainda os **odds** (razão das chances) $\frac{p}{1-p} \in [0, \infty]$.
- Consideramos a obtenção do **log-odds** $\log \frac{p}{1-p} \in [-\infty, \infty]$.
- Partimos de uma transformação linear para calcular o log-odds:

$$\log \frac{p}{1-p} = \mathbf{w}^\top \mathbf{x},$$

$$\log \frac{1-p}{p} = -\mathbf{w}^\top \mathbf{x},$$

$$\frac{1-p}{p} = \exp(-\mathbf{w}^\top \mathbf{x})$$

$$\frac{1}{p} = 1 + \exp(-\mathbf{w}^\top \mathbf{x})$$

$$p = \frac{1}{1 + \exp(-\mathbf{w}^\top \mathbf{x})} = \sigma(\mathbf{w}^\top \mathbf{x}).$$

Regressão logística binária

- Como surge a fronteira de decisão linear?

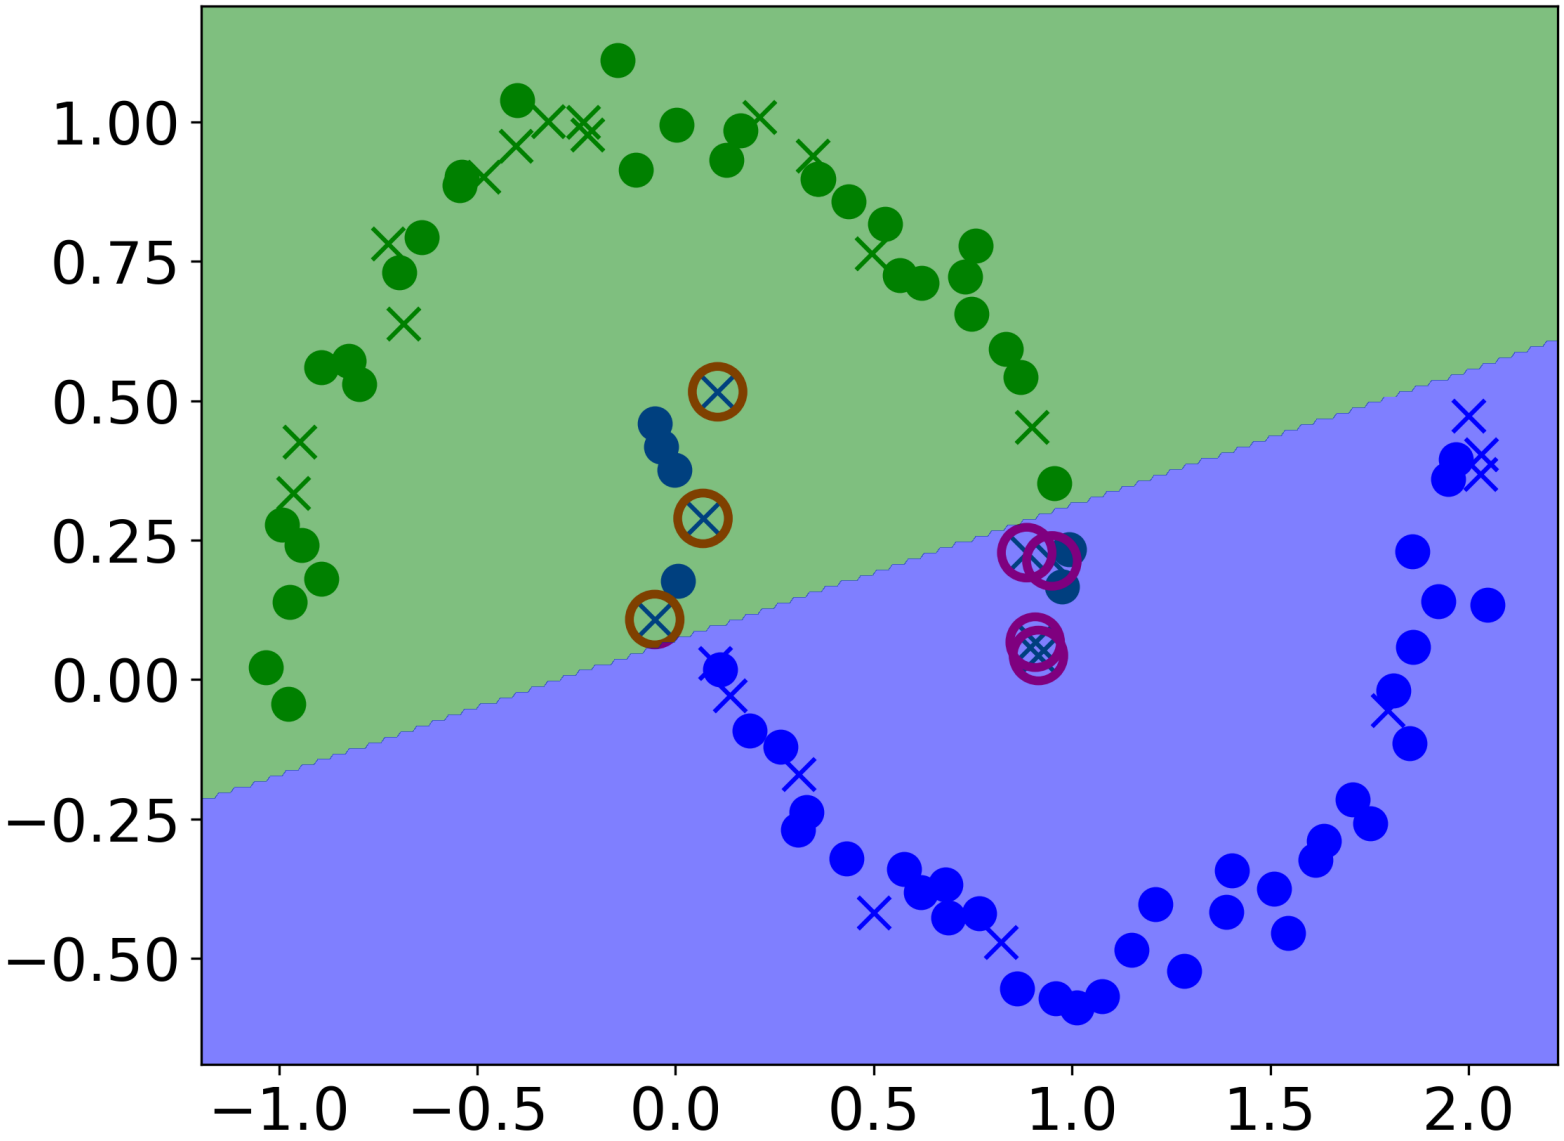
Regressão logística binária

- Como surge a fronteira de decisão linear?
- A classe predita k_* para uma entrada $\mathbf{x}_*$ é dada por:

$$
\begin{aligned}
k_* &= \begin{cases} 0, & p(y_*|\mathbf{x}_*, \mathbf{w}) < 0.5 \\ 1, & p(y_*|\mathbf{x}_*, \mathbf{w}) \geq 0.5 \end{cases}, \\
&= \begin{cases} 0, & \sigma(\mathbf{w}^\top \mathbf{x}_*) < 0.5 \\ 1, & \sigma(\mathbf{w}^\top \mathbf{x}_*) \geq 0.5 \end{cases}, \\
&= \begin{cases} 0, & \frac{1}{1+\exp(-\mathbf{w}^\top \mathbf{x}_*)} < 0.5 \\ 1, & \frac{1}{1+\exp(-\mathbf{w}^\top \mathbf{x}_*)} \geq 0.5 \end{cases}, \\
&= \begin{cases} 0, & 1 + \exp(-\mathbf{w}^\top \mathbf{x}_*) > 2 \\ 1, & 1 + \exp(-\mathbf{w}^\top \mathbf{x}_*) \leq 2 \end{cases}, \\
&= \begin{cases} 0, & \mathbf{w}^\top \mathbf{x}_* < 0 \\ 1, & \mathbf{w}^\top \mathbf{x}_* \geq 0 \end{cases}.
\end{aligned}
$$

- Como $\mathbf{w}^\top \mathbf{x}_*$ define um hiperplano, a fronteira é linear.

Exemplo de classificação (dados não separáveis linearmente)



Regressão logística binária

Extensões da regressão logística

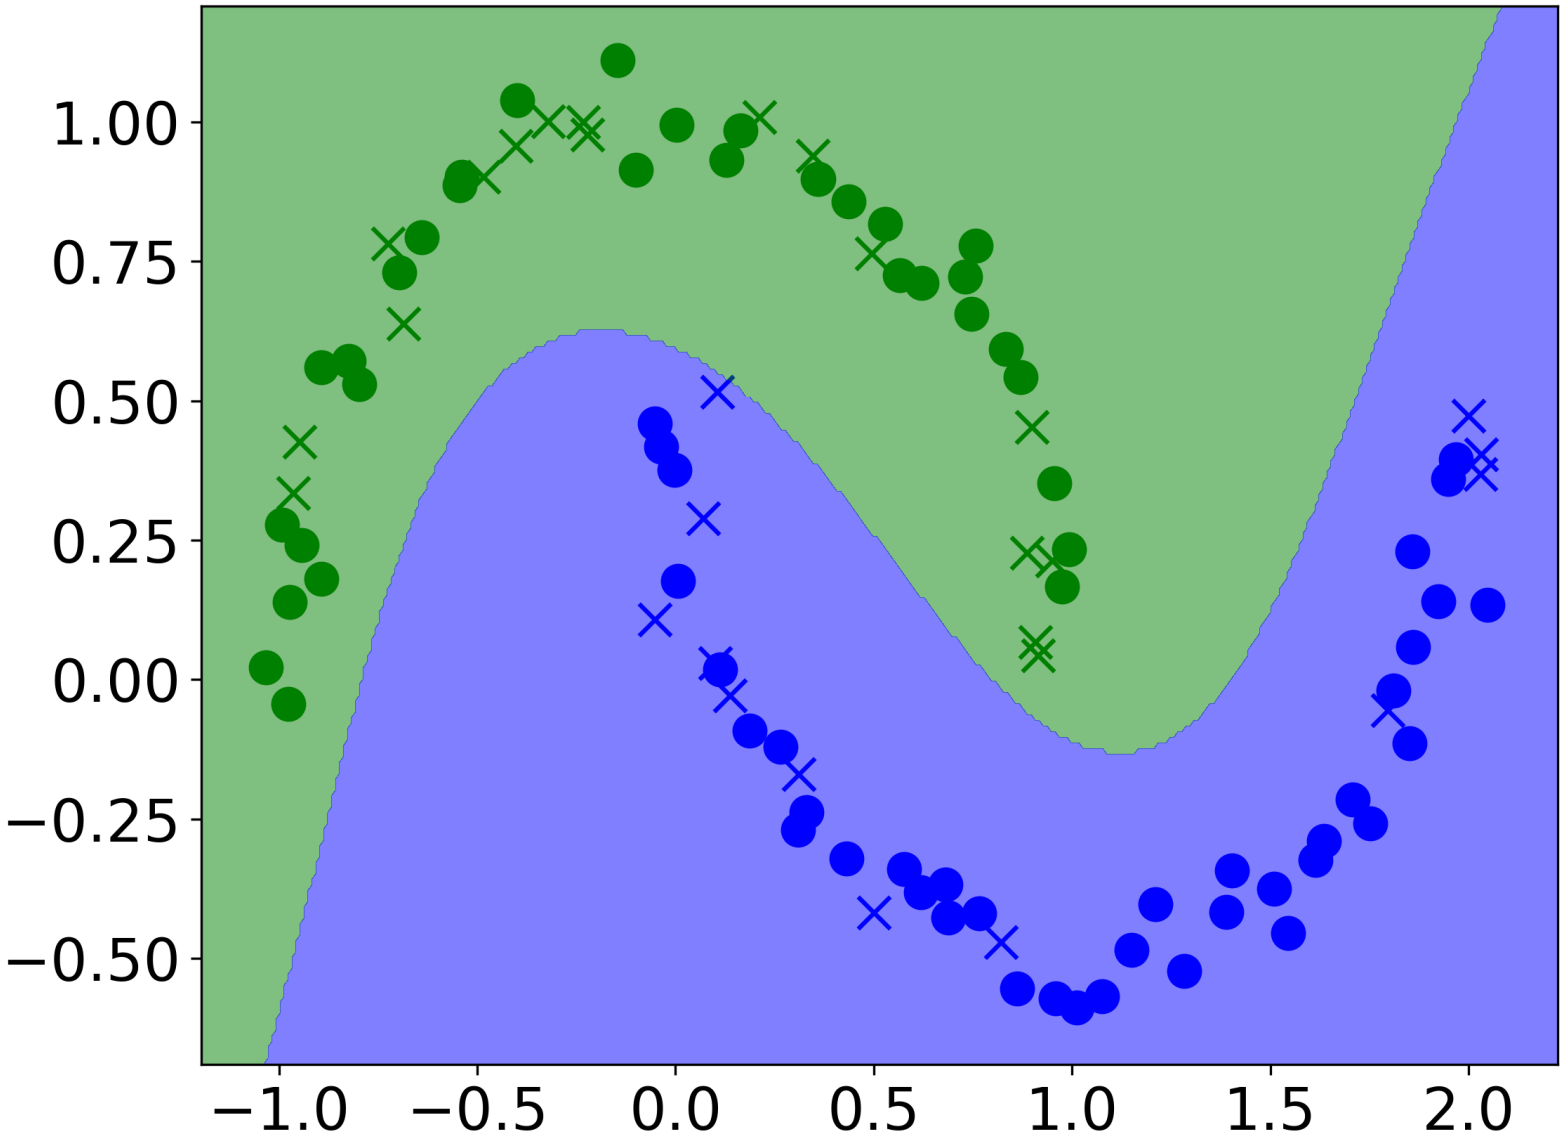
- Novos **atributos não-lineares** $(x_i^2, x_i^3, \cdots)$ podem ser incluídos para obter um **classificador não-linear**.

Regressão logística binária

Extensões da regressão logística

- Novos **atributos não-lineares** $(x_i^2, x_i^3, \cdots)$ podem ser incluídos para obter um **classificador não-linear**.
- Modelos de regressão logística também podem ser **regularizados**.
  - Inclui na função custo o termo: $+\lambda\|\mathbf{w}\|^2$.
  - Inclui na regra de atualização o termo: $-\lambda\mathbf{w}(t-1)$.

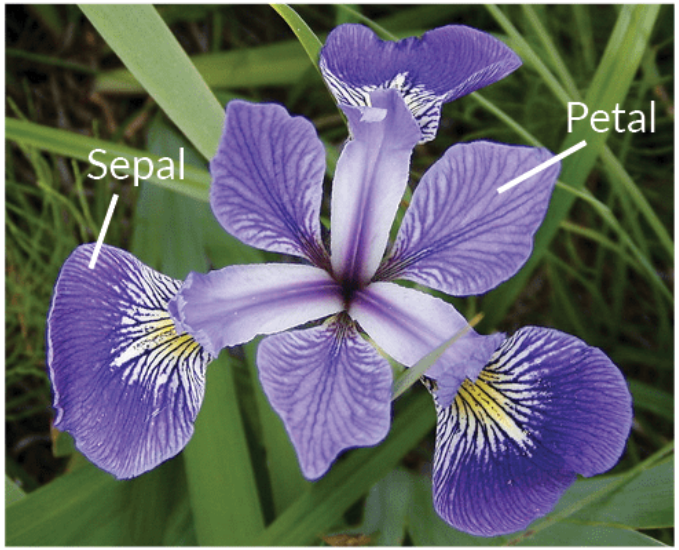
Exemplo de classificação com atributos polinomiais



Agenda

1. Classificação binária
2. Regressão logística binária
3. Regressão logística multiclasse
4. Regressão logística via algoritmo IRLS
5. Regressão logística Bayesiana - Aproximação de Laplace
6. Tópicos adicionais
7. Referências

Classificação multiclasse



Iris Versicolor



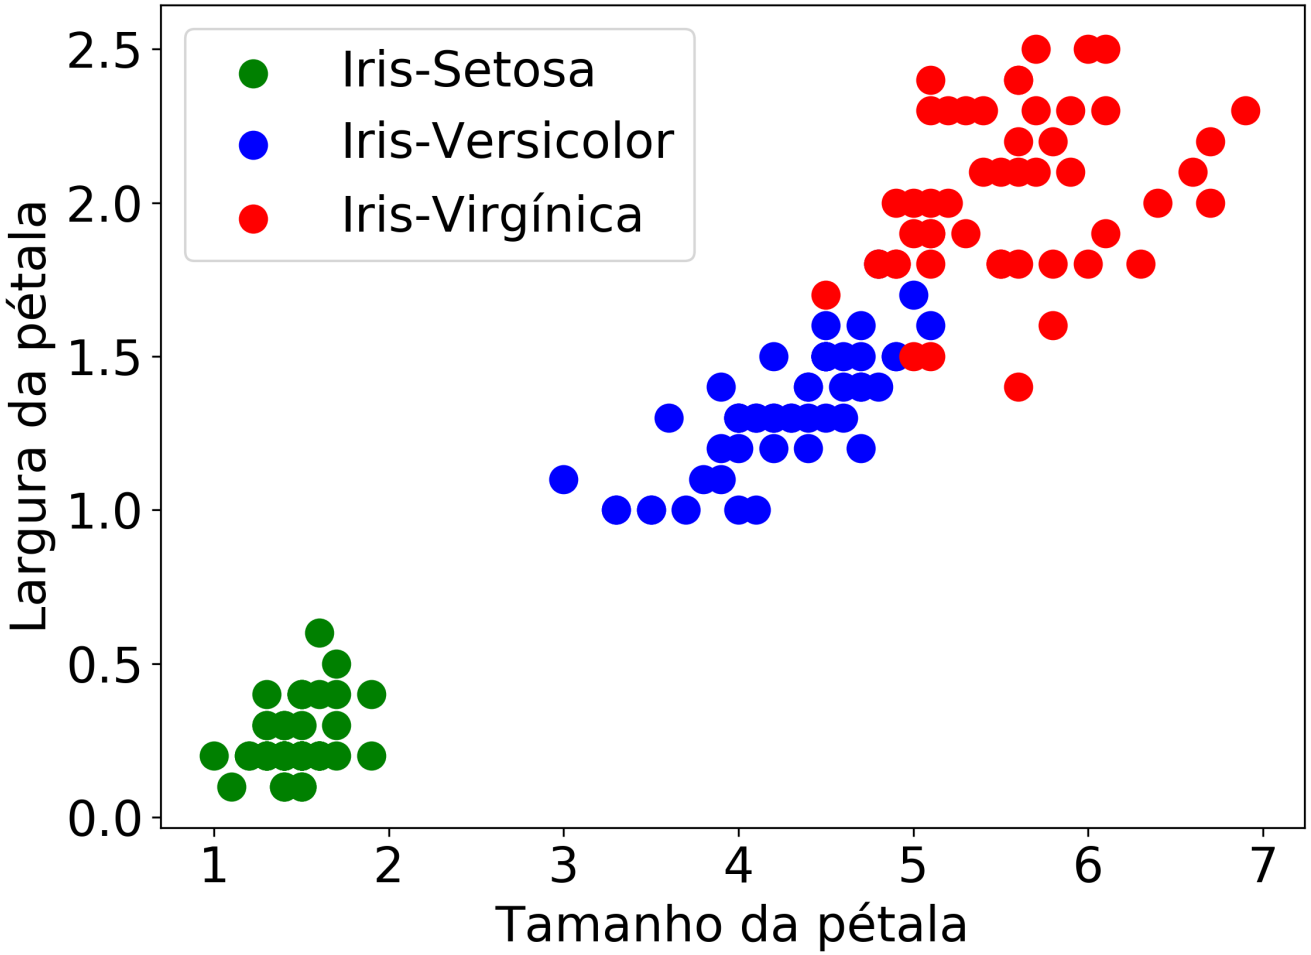
Iris Setosa



Iris Virginica

- **Problema**: Como classificar automaticamente flores da espécie íris entre Setosa, Versicolor e Virgínica a partir de medidas de suas pétalas?

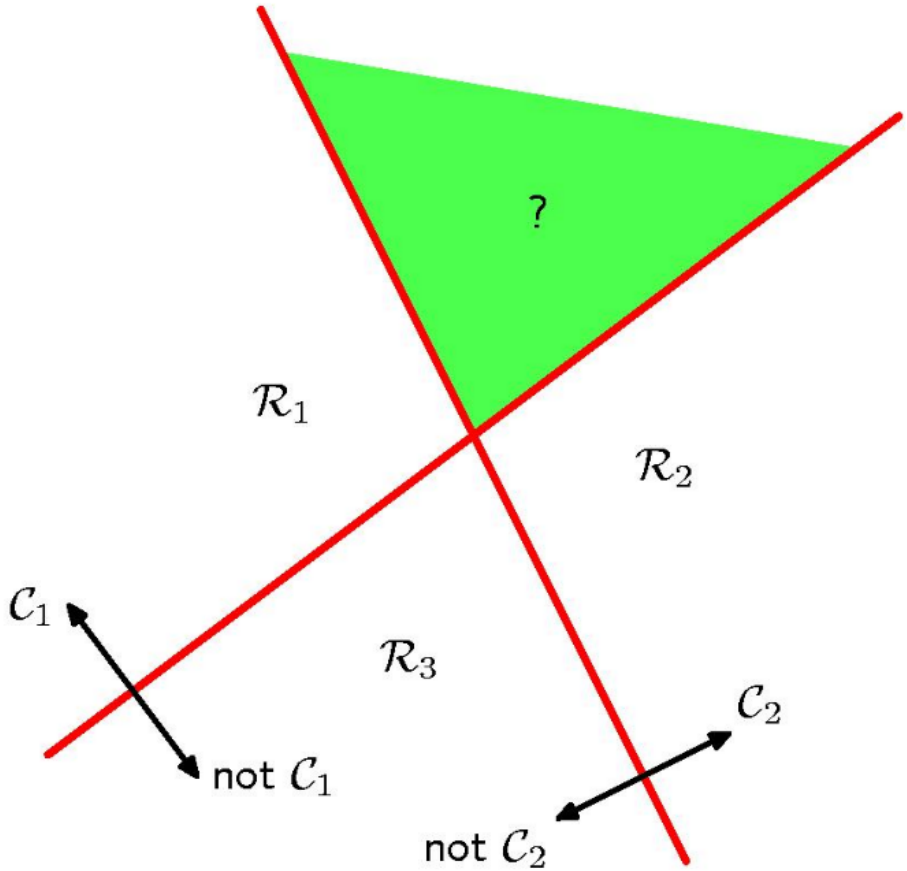
Classificação multiclasse



- **Problema**: Como representamos as classes na saída do modelo?

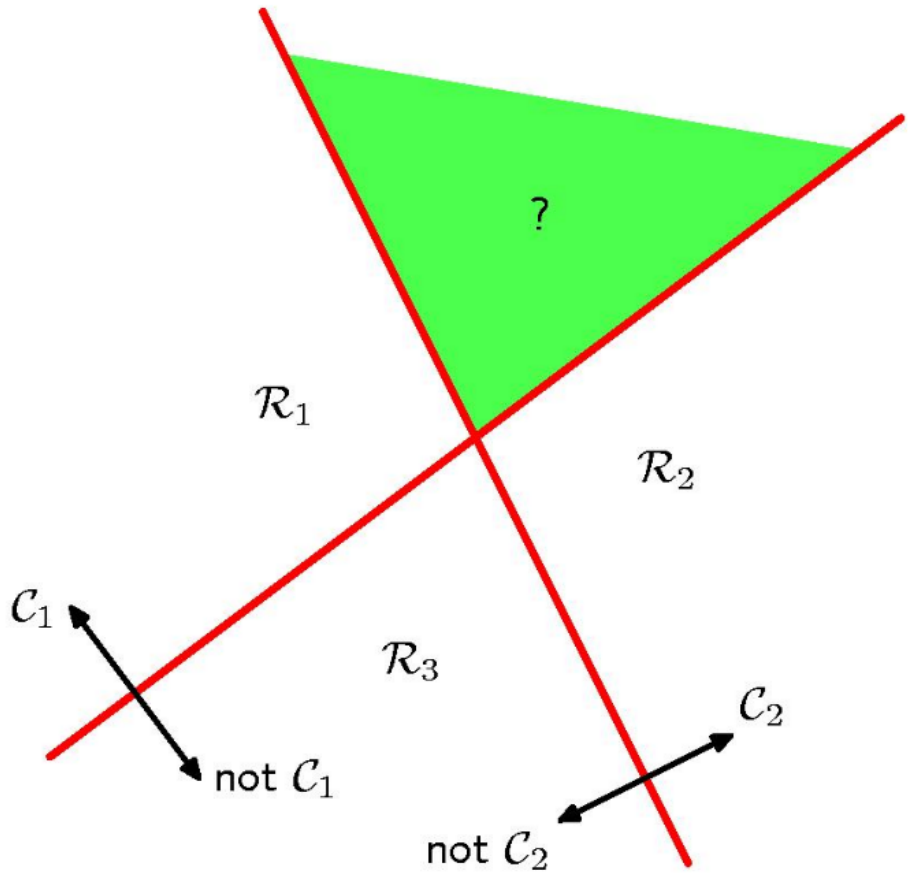
Classificação multiclasse

- **Ideia**: $K - 1$ classificações binárias **one vs all**:



Classificação multiclasse

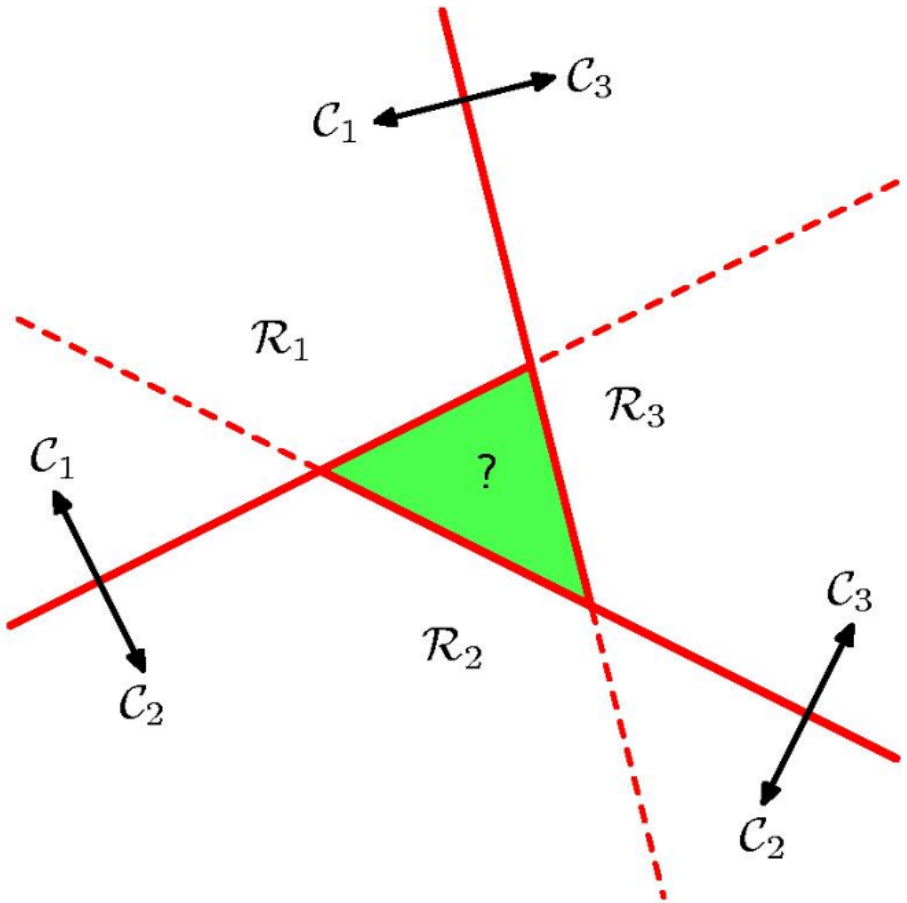
- **Ideia**: $K - 1$ classificações binárias **one vs all**:



- **Problema**: Regiões não associadas a uma única classe.

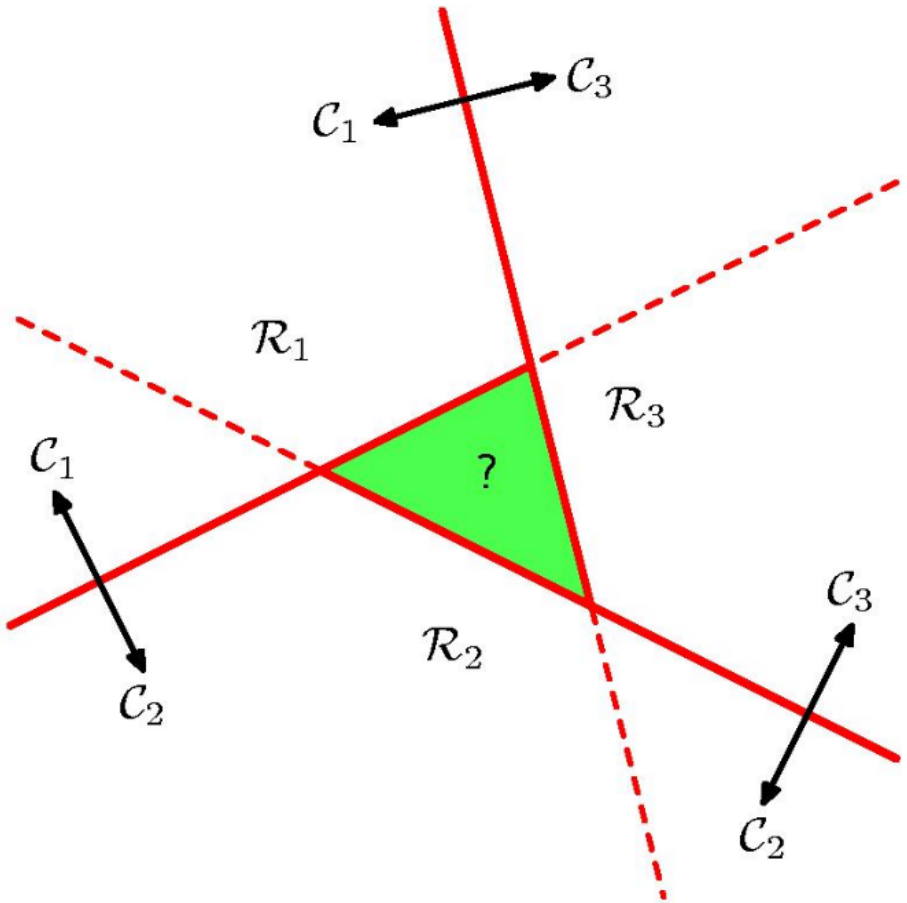
Classificação multiclasse

- **Ideia**: $K(K-1)/2$ classificações binárias **one vs one**:



Classificação multiclasse

- **Ideia**: $K(K-1)/2$ classificações binárias **one vs one**:



- **Problema**: Regiões não associadas a uma única classe.

Classificação multiclasse

One hot encoding (1-of-K encoding)

- A saída do modelo é um vetor de K elementos (K = número de classes).
- O vetor de saída desejado $\mathbf{y}_i$ consiste em um vetor de $K-1$ zeros e um valor 1 na k-ésima posição associada à k-ésima classe.
- **Exemplo**: $\mathbf{y}_i = [1\ 0\ 0]^\top$, ou $\mathbf{y}_i = [0\ 1\ 0]^\top$, ou $\mathbf{y}_i = [0\ 0\ 1]^\top$.

Classificação multiclasse

One hot encoding (1-of-K encoding)

- A saída do modelo é um vetor de K elementos (K = número de classes).
- O vetor de saída desejado $\mathbf{y}_i$ consiste em um vetor de $K-1$ zeros e um valor 1 na k-ésima posição associada à k-ésima classe.
- **Exemplo**: $\mathbf{y}_i = [1\ 0\ 0]^\top$, ou $\mathbf{y}_i = [0\ 1\ 0]^\top$, ou $\mathbf{y}_i = [0\ 0\ 1]^\top$.

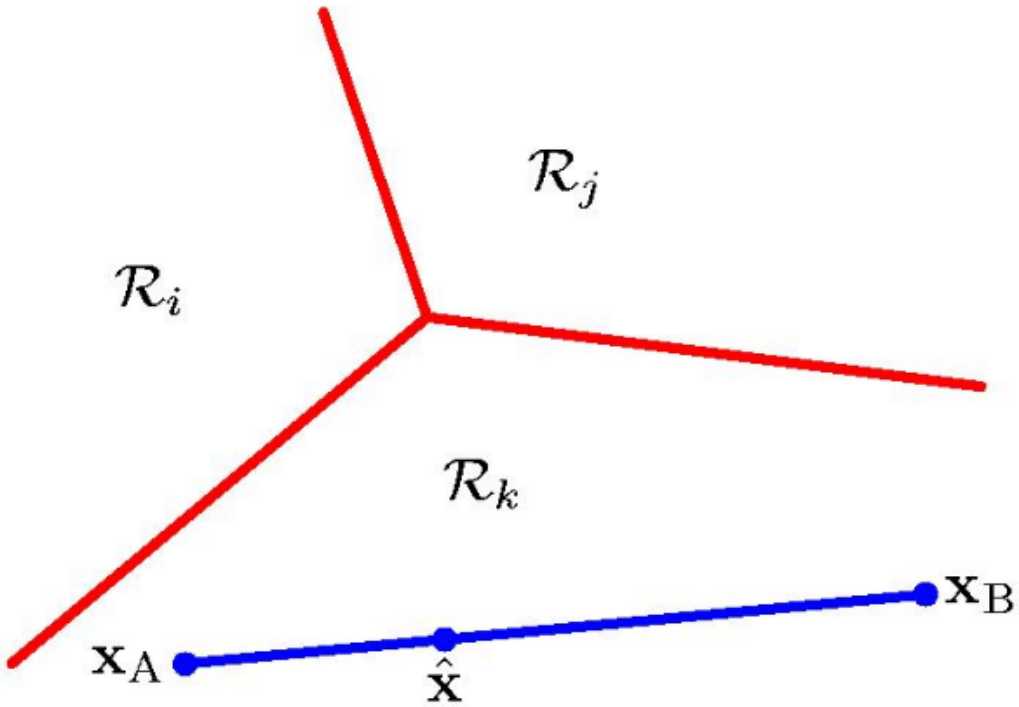
Discriminante linear

- Dado um total de K classes, a classe k_* predita para o padrão $\mathbf{x}_*$ é dada por:

$$k_* = \arg \max_{1 \leq k \leq K} \hat{y}_k.$$

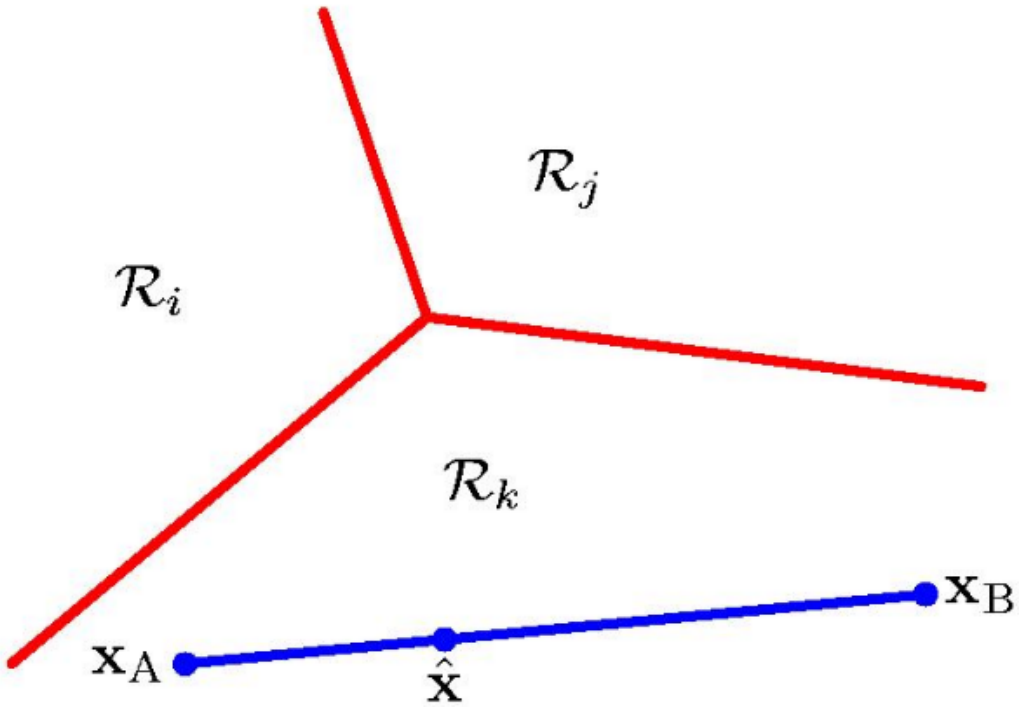
Classificação multiclasse

- As regiões definidas por um discriminante linear são **convexas**:



Classificação multiclasse

- As regiões definidas por um discriminante linear são **convexas**:



- **Problema**: Notação do modelo com múltiplas saídas?

Regressão multivariada

- Nova notação matricial:

$$\hat{\mathbf{y}}_i = \mathbf{W}^\top \mathbf{x}_i,$$
$$\hat{\mathbf{Y}} = \mathbf{X}\mathbf{W},$$

$\rightarrow$ $\mathbf{W} \in \mathbb{R}^{D \times K}$ é a matriz de parâmetros do modelo.
$\rightarrow$ $\mathbf{X} \in \mathbb{R}^{N \times D}$ é a coleção de entradas do modelo.
$\rightarrow$ $\hat{\mathbf{Y}} \in \mathbb{R}^{N \times K}$ é a coleção de saídas do modelo.

Regressão multivariada

OLS para regressão multivariada (múltiplas saídas)

- **Função custo**:

$$\mathcal{J}(\mathbf{W}) = \frac{1}{2}\|\mathbf{Y} - \hat{\mathbf{Y}}\|_F^2 = \frac{1}{2}\sum_{i=1}^{N}\|\mathbf{y}_i - \hat{\mathbf{y}}_i\|^2 = \frac{1}{2}\sum_{i=1}^{N}\sum_{k=1}^{K}|y_{ik} - \hat{y}_{ik}|^2,$$

  em que $\|\cdot\|_F$ é a **Norma de Frobenius**.

- **Solução analítica**:

$$\mathbf{W} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{Y}.$$

Regressão multivariada

Gradiente Descendente para múltiplas saídas

- Regra de atualização:

$$\mathbf{w}_k(t) = \mathbf{w}_k(t-1) + \alpha \frac{1}{N} \sum_{i=1}^{N} e_{ik}(t-1)\mathbf{x}_i$$

Gradiente Descendente Estocástico para múltiplas saídas

- Regra de atualização:

$$\mathbf{w}_k(t) = \mathbf{w}_k(t-1) + \alpha e_{ik}(t-1)\mathbf{x}_i$$

- Note que:

$\rightarrow$ $e_{ik} = y_{ik} - \hat{y}_{ik}$

$\rightarrow$ $\mathbf{W} = [\mathbf{w}_1 \cdots \mathbf{w}_k \cdots \mathbf{w}_K], \mathbf{w}_k \in \mathbb{R}^D$

Classificação multiclasse

Regressão logística multiclasse

- A coluna $\mathbf{w}_k$ da matriz $\mathbf{W}$ está associada à classe k.

Classificação multiclasse

Regressão logística multiclasse

- A coluna $\mathbf{w}_k$ da matriz $\mathbf{W}$ está associada à classe k.
- Para a saída do modelo, usamos a função **softmax**:

$$\hat{y}_{ik} = \frac{\exp(\mathbf{w}_k^\top \mathbf{x}_i)}{\sum_{j=1}^{K} \exp(\mathbf{w}_j^\top \mathbf{x}_i)}, \quad 1 \leq k \leq K.$$

Classificação multiclasse

Regressão logística multiclasse

- A coluna $\mathbf{w}_k$ da matriz $\mathbf{W}$ está associada à classe k.
- Para a saída do modelo, usamos a função **softmax**:

$$\hat{y}_{ik} = \frac{\exp(\mathbf{w}_k^\top \mathbf{x}_i)}{\sum_{j=1}^{K} \exp(\mathbf{w}_j^\top \mathbf{x}_i)}, \quad 1 \leq k \leq K.$$

- Interpretação probabilística: $\hat{y}_{ik} = p(y_{ik}|\mathbf{x}_i, \mathbf{W}) \in [0, 1]$.
- Também chamada de **regressão softmax** ou **regressão logística multinomial**.

Classificação multiclasse

Regressão logística multiclasse

- A coluna $\mathbf{w}_k$ da matriz $\mathbf{W}$ está associada à classe k.
- Para a saída do modelo, usamos a função **softmax**:

$$\hat{y}_{ik} = \frac{\exp(\mathbf{w}_k^\top \mathbf{x}_i)}{\sum_{j=1}^{K} \exp(\mathbf{w}_j^\top \mathbf{x}_i)}, \quad 1 \leq k \leq K.$$

- Interpretação probabilística: $\hat{y}_{ik} = p(y_{ik}|\mathbf{x}_i, \mathbf{W}) \in [0, 1]$.
- Também chamada de **regressão softmax** ou **regressão logística multinomial**.

- **Problema**: Qual será a nova função custo?

Regressão logística multiclasse

Multiclass cross-entropy

- Função custo para regressão logística multiclasse:

$$\mathcal{J}(\mathbf{W}) = -\frac{1}{N} \log p(\mathbf{Y}|\mathbf{X}, \mathbf{W})$$

$$\mathcal{J}(\mathbf{W}) = -\frac{1}{N} \log \prod_{i=1}^{N} \prod_{k=1}^{K} p(y_{ik}|\mathbf{x}_i, \mathbf{W})^{y_{ik}}$$

$$\mathcal{J}(\mathbf{W}) = -\frac{1}{N} \sum_{i=1}^{N} \sum_{k=1}^{K} y_{ik} \log \hat{y}_{ik}.$$

- Precisamos calcular o gradiente da função custo para atualizar os parâmetros do modelo:

$$\mathbf{W} \leftarrow \mathbf{W} - \alpha \frac{\partial \mathcal{J}(\mathbf{W})}{\partial \mathbf{W}}, \text{ ou } \mathbf{w}_k \leftarrow \mathbf{w}_k - \alpha \frac{\partial \mathcal{J}(\mathbf{W})}{\partial \mathbf{w}_k}, \forall k.$$

Regressão logística multiclasse

- As derivadas em relação aos parâmetros são dadas por:

$$\mathcal{J}(\mathbf{W}) = -\frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{K} y_{ij}\log \hat{y}_{ij},$$

$$\frac{\partial \mathcal{J}}{\partial \mathbf{w}_k} = -\frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{K} \frac{y_{ij}}{\hat{y}_{ij}}\frac{\partial \hat{y}_{ij}}{\partial \mathbf{w}_k}, \text{ em que:}$$

$$\frac{\partial \hat{y}_{ik}}{\partial \mathbf{w}_k} = \frac{\partial}{\partial \mathbf{w}_k}\left[\frac{\exp(\mathbf{w}_k^\top \mathbf{x}_i)}{\sum_{c=1}^{K}\exp(\mathbf{w}_c^\top \mathbf{x}_i)}\right] = (\hat{y}_{ik} - \hat{y}_{ik}^2)\mathbf{x}_i, \quad \text{se } j = k,$$

$$\frac{\partial \hat{y}_{ij}}{\partial \mathbf{w}_k} = \frac{\partial}{\partial \mathbf{w}_k}\left[\frac{\exp(\mathbf{w}_j^\top \mathbf{x}_i)}{\sum_{c=1}^{K}\exp(\mathbf{w}_c^\top \mathbf{x}_i)}\right] = -\hat{y}_{ij}\hat{y}_{ik}\mathbf{x}_i, \quad \text{se } j \neq k,$$

ou seja: $\frac{\partial \hat{y}_{ij}}{\partial \mathbf{w}_k} = [\delta(j,k)\hat{y}_{ik} - \hat{y}_{ij}\hat{y}_{ik}]\mathbf{x}_i, \quad \delta(j,k) = \begin{cases} 1, & j = k, \\ 0, & j \neq k \end{cases}.$

Regressão logística multiclasse

- Substituindo na derivada original:

$$\frac{\partial \mathcal{J}}{\partial \mathbf{w}_k} = -\frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{K}\frac{y_{ij}}{\hat{y}_{ij}}[\delta(j,k)\hat{y}_{ij} - \hat{y}_{ij}\hat{y}_{ik}]\mathbf{x}_i$$

$$\frac{\partial \mathcal{J}}{\partial \mathbf{w}_k} = -\frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{K} y_{ij}[\delta(j,k) - \hat{y}_{ik}]\mathbf{x}_i$$

$$\frac{\partial \mathcal{J}}{\partial \mathbf{w}_k} = -\frac{1}{N}\sum_{i=1}^{N}\left[\sum_{j=1}^{K} y_{ij}\delta(j,k) - \hat{y}_{ik}\underbrace{\sum_{j=1}^{K} y_{ij}}_{=1}\right]\mathbf{x}_i$$

$$\frac{\partial \mathcal{J}}{\partial \mathbf{w}_k} = -\frac{1}{N}\sum_{i=1}^{N}\left[y_{ik} - \hat{y}_{ik}\right]\mathbf{x}_i = -\frac{1}{N}\sum_{i=1}^{N} e_{ik}\mathbf{x}_i.$$

- Note que a soma dos elementos do vetor $\mathbf{y}_i$ é igual a 1.

Regressão logística multiclasse

- Com os gradientes $\frac{\partial \mathcal{J}(\mathbf{W})}{\partial \mathbf{w}_k}$, atualizamos o modelo via GD/SGD.

Gradiente Descendente para múltiplas saídas

- Regra de atualização:

$$\mathbf{w}_k(t) = \mathbf{w}_k(t-1) + \alpha \frac{1}{N} \sum_{i=1}^{N} e_{ik}(t-1)\mathbf{x}_i$$

Gradiente Descendente Estocástico para múltiplas saídas

- Regra de atualização:

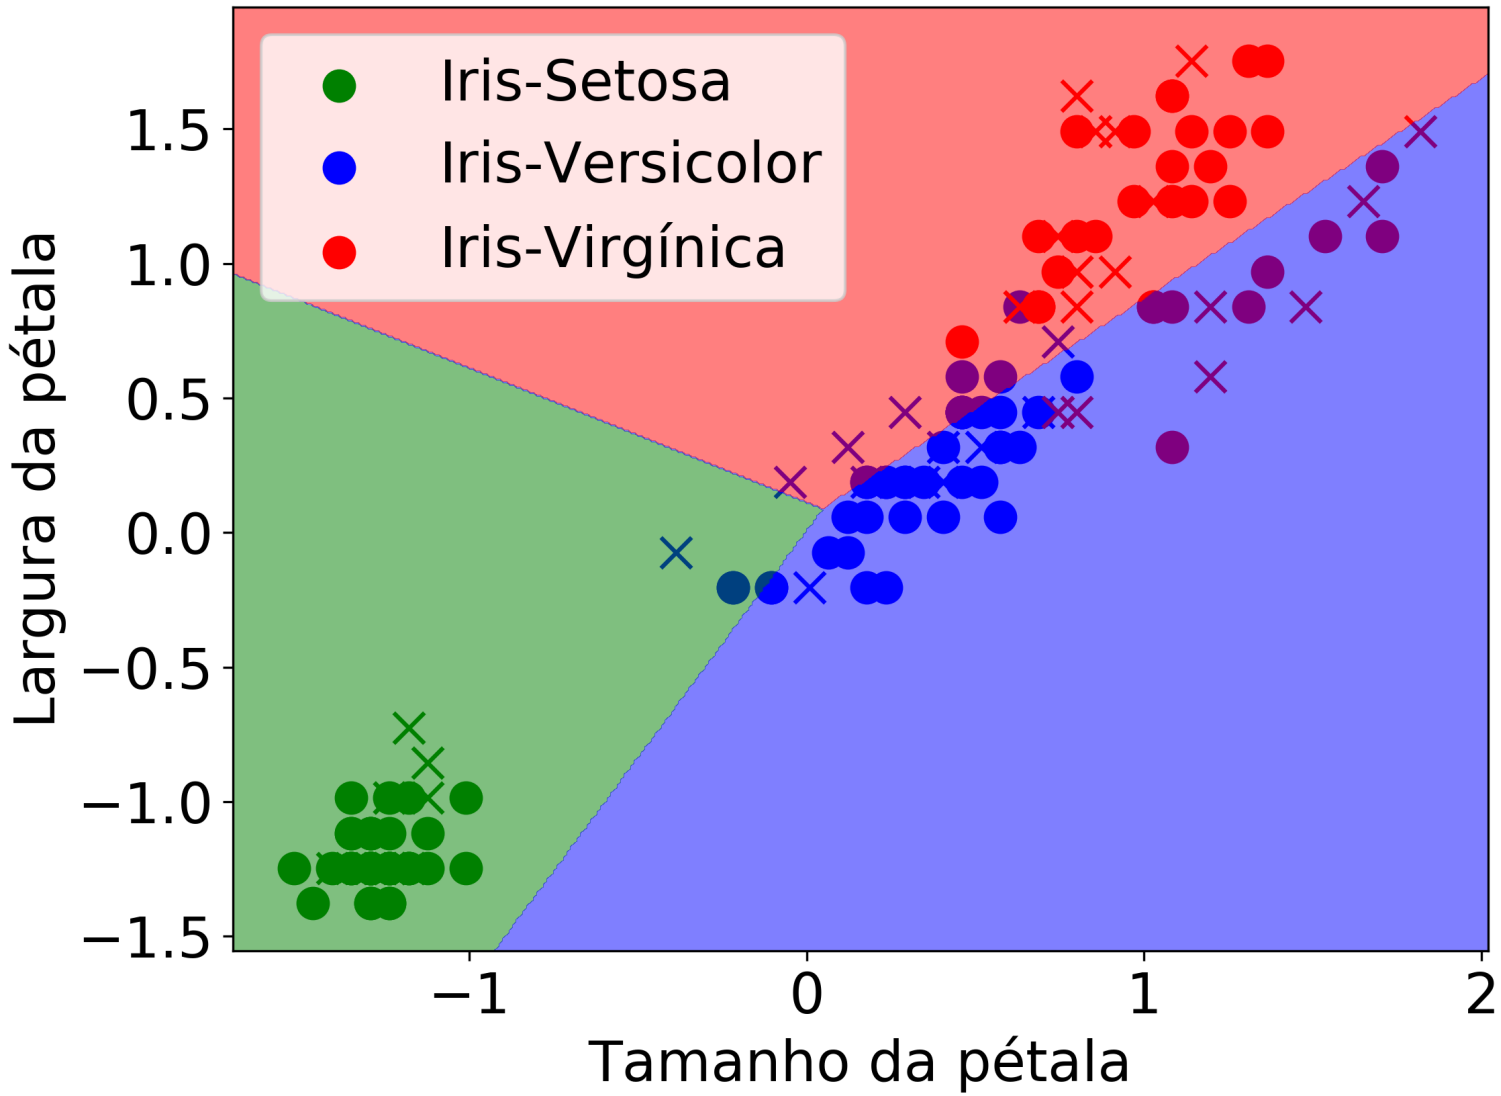
$$\mathbf{w}_k(t) = \mathbf{w}_k(t-1) + \alpha e_{ik}(t-1)\mathbf{x}_i$$

- Lembrando que na regressão logística multiclasse temos:

$$e_{ik}(t) = y_{ik} - \frac{\exp(\mathbf{w}_k(t)^\top \mathbf{x}_i)}{\sum_{j=1}^{K} \exp(\mathbf{w}_j(t)^\top \mathbf{x}_i)}.$$

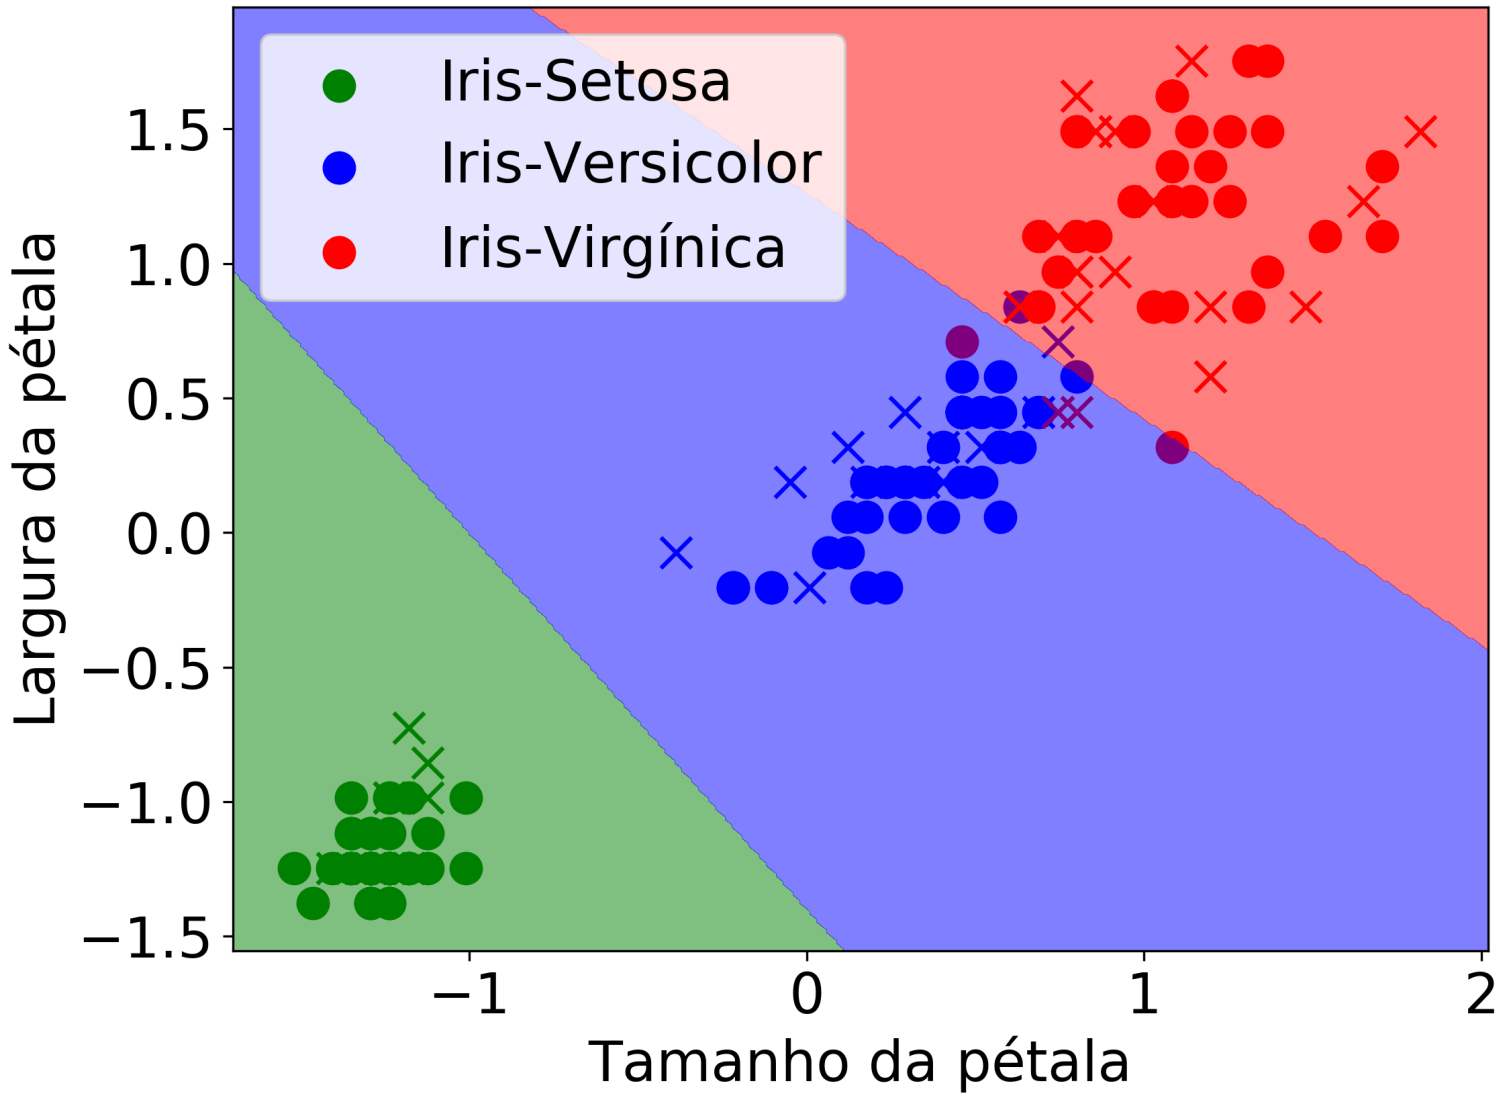
Classificação multiclasse

Regressão linear "ingênua" (OLS) - 72.73% de acurácia no teste



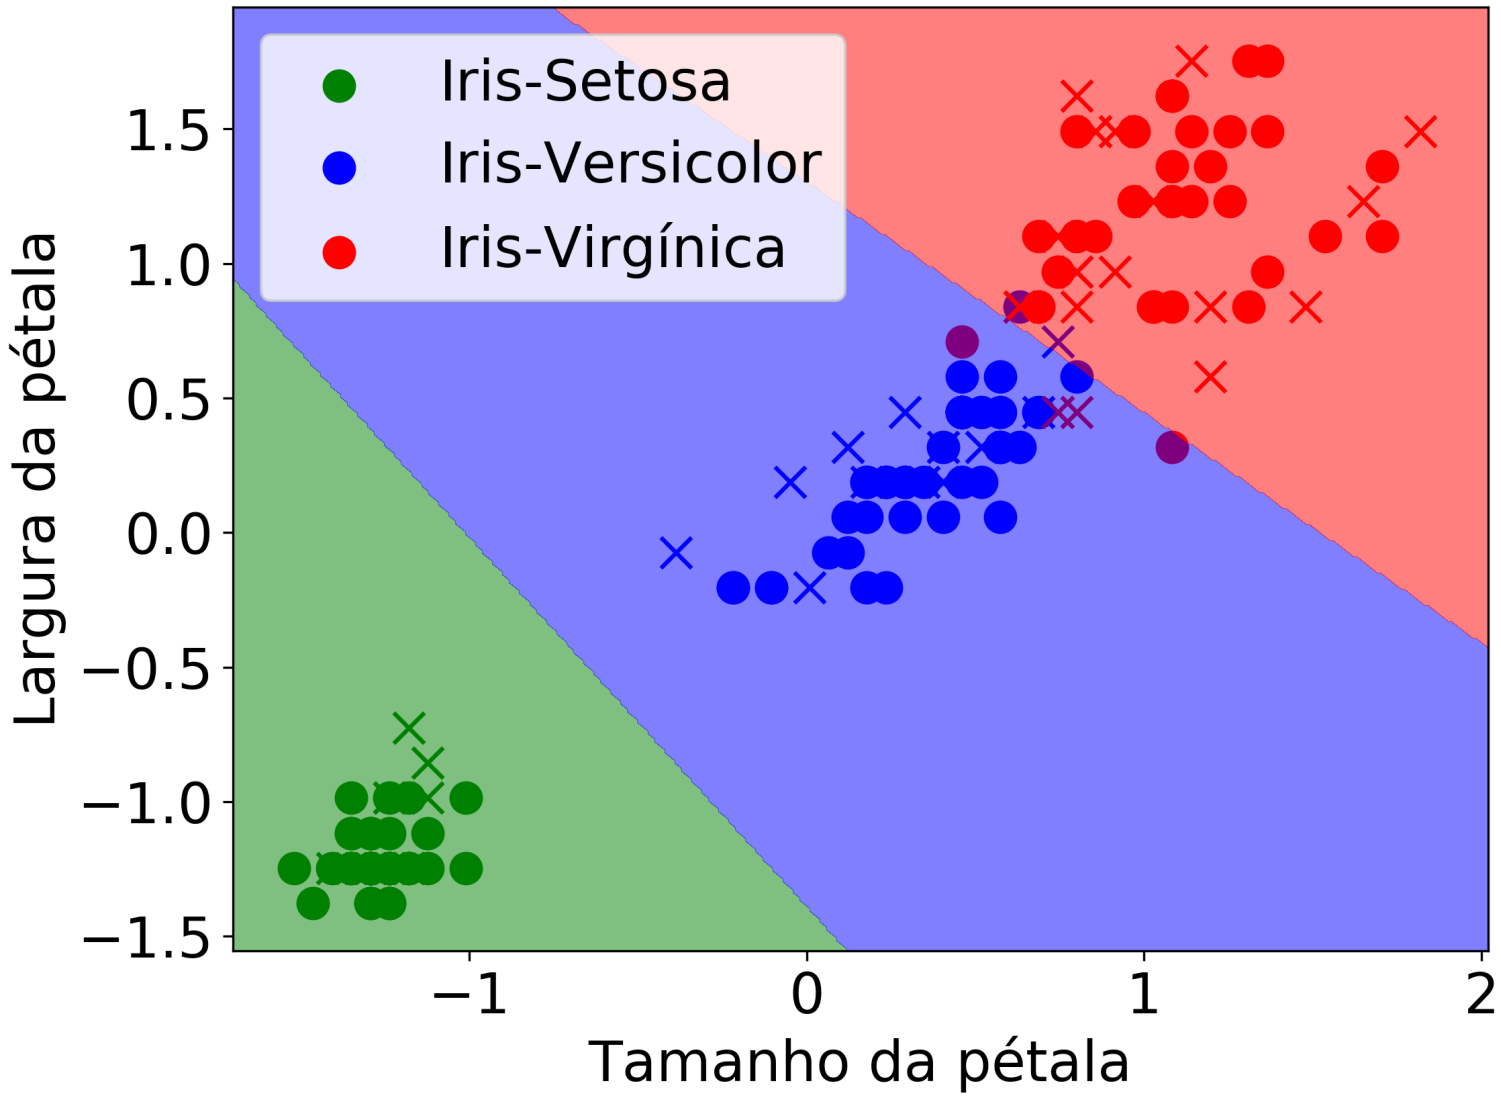
Classificação multiclasse

Regressão logística (GD) - 93.18% de acurácia no teste



Classificação multiclasse

Regressão logística (SGD) - 93.18% de acurácia no teste



Regressão logística multiclasse

- Podemos derivar a regressão logística multiclasse estendendo o conceito da regressão logística binária.

Regressão logística multiclasse

- Podemos derivar a regressão logística multiclasse estendendo o conceito da regressão logística binária.
- Consideramos o *log-odds* entre K-1 classes e a classe K, semelhante ao caso binário:

$$\log \frac{p(y_{ik}|\mathbf{x}_i, \mathbf{W})}{p(y_{iK}|\mathbf{x}_i, \mathbf{W})} = \mathbf{w}_k^\top \mathbf{x}_i, \quad 1 \leq k \leq K-1,$$

$$p(y_{ik}|\mathbf{x}_i, \mathbf{W}) = \exp(\mathbf{w}_k^\top \mathbf{x}_i) p(y_{iK}|\mathbf{x}_i, \mathbf{W}), \quad 1 \leq k \leq K-1,$$

$$p(y_{iK}|\mathbf{x}_i, \mathbf{W}) = 1 - \sum_{k=1}^{K-1} p(y_{ik}|\mathbf{x}_i, \mathbf{W}),$$

em que o resultado é equivariante à escolha da K-ésima classe.

Regressão logística multiclasse

- Trabalhando as expressões anteriores:

$$p(y_{ik}|\mathbf{x}_i, \mathbf{W}) = \exp(\mathbf{w}_k^\top \mathbf{x}_i) p(y_{iK}|\mathbf{x}_i, \mathbf{W})$$

$$\sum_{k=1}^{K-1} \exp(\mathbf{w}_k^\top \mathbf{x}_i) p(y_{iK}|\mathbf{x}_i, \mathbf{W}) = 1 - p(y_{iK}|\mathbf{x}_i, \mathbf{W}),$$

$$\sum_{k=1}^{K-1} \exp(\mathbf{w}_k^\top \mathbf{x}_i) = \frac{1}{p(y_{iK}|\mathbf{x}_i, \mathbf{W})} - 1,$$

$$p(y_{iK}|\mathbf{x}_i, \mathbf{W}) = \frac{1}{1 + \sum_{k=1}^{K-1} \exp(\mathbf{w}_k^\top \mathbf{x}_i)}.$$

Regressão logística multiclasse

- Trabalhando as expressões anteriores:

$$p(y_{ik}|\mathbf{x}_i, \mathbf{W}) = \exp(\mathbf{w}_k^\top \mathbf{x}_i) p(y_{iK}|\mathbf{x}_i, \mathbf{W})$$

$$\sum_{k=1}^{K-1} \exp(\mathbf{w}_k^\top \mathbf{x}_i) p(y_{iK}|\mathbf{x}_i, \mathbf{W}) = 1 - p(y_{iK}|\mathbf{x}_i, \mathbf{W}),$$

$$\sum_{k=1}^{K-1} \exp(\mathbf{w}_k^\top \mathbf{x}_i) = \frac{1}{p(y_{iK}|\mathbf{x}_i, \mathbf{W})} - 1,$$

$$p(y_{iK}|\mathbf{x}_i, \mathbf{W}) = \frac{1}{1 + \sum_{k=1}^{K-1} \exp(\mathbf{w}_k^\top \mathbf{x}_i)}.$$

- Logo, $p(y_{ik}|\mathbf{x}_i, \mathbf{W}) = \frac{\exp(\mathbf{w}_k^\top \mathbf{x}_i)}{1+\sum_{j=1}^{K-1} \exp(\mathbf{w}_j^\top \mathbf{x}_i)}, \quad 1 \leq k \leq K-1.$

Regressão logística multiclasse

- De onde vem a função softmax?

Regressão logística multiclasse

- De onde vem a função softmax?
- Lembramos que o logaritmo da probabilidade da classe k é proporcional à k-ésima saída do modelo linear:

$$\log p(y_{ik}|\mathbf{x}_i, \mathbf{W}) \propto \mathbf{w}_k^\top \mathbf{x}_i \qquad , 1 \leq k \leq K$$
$$\log p(y_{ik}|\mathbf{x}_i, \mathbf{W}) = \mathbf{w}_k^\top \mathbf{x}_i - \log Z \qquad , 1 \leq k \leq K$$
$$p(y_{ik}|\mathbf{x}_i, \mathbf{W}) = \frac{1}{Z} \exp(\mathbf{w}_k^\top \mathbf{x}_i) \qquad , 1 \leq k \leq K.$$

Regressão logística multiclasse

- Como a soma das probabilidades das classes deve ser igual a 1:

$$1 = \sum_{k=1}^{K} p(y_{ik}|\mathbf{x}_i, \mathbf{W}) = \sum_{k=1}^{K} \frac{1}{Z} \exp(\mathbf{w}_k^\top \mathbf{x}_i).$$

- Logo, temos a função de partição $Z = \frac{1}{\sum_{k=1}^{K} \exp(\mathbf{w}_k^\top \mathbf{x}_i)}$.
- Substituindo na expressão original, temos:

$$p(y_{ik}|\mathbf{x}_i, \mathbf{W}) = \frac{\exp(\mathbf{w}_k^\top \mathbf{x}_i)}{\sum_{j=1}^{K} \exp(\mathbf{w}_j^\top \mathbf{x}_i)}, 1 \leq k \leq K.$$

Regressão logística multiclasse

- Como a soma das probabilidades das classes deve ser igual a 1:

$$1 = \sum_{k=1}^{K} p(y_{ik}|\mathbf{x}_i, \mathbf{W}) = \sum_{k=1}^{K} \frac{1}{Z} \exp(\mathbf{w}_k^\top \mathbf{x}_i).$$

- Logo, temos a função de partição $Z = \frac{1}{\sum_{k=1}^{K} \exp(\mathbf{w}_k^\top \mathbf{x}_i)}$.
- Substituindo na expressão original, temos:

$$p(y_{ik}|\mathbf{x}_i, \mathbf{W}) = \frac{\exp(\mathbf{w}_k^\top \mathbf{x}_i)}{\sum_{j=1}^{K} \exp(\mathbf{w}_j^\top \mathbf{x}_i)}, 1 \leq k \leq K.$$

- Note que temos um modelo sobreparametrizado, pois $p(y_{iK}|\mathbf{x}_i, \mathbf{W}) = 1 - \sum_{j=1}^{K-1} p(y_{ij}|\mathbf{x}_i, \mathbf{W})$.
- Podemos então fazer $\mathbf{w}_K = \mathbf{0}$ e obter o mesmo resultado da versão estendida da regressão logística.

Regressão logística multiclasse

- A função softmax para a k-ésima classe pode ser denotada por:

$$\mathcal{S}_k(\mathbf{x}_i, \mathbf{W}) = \frac{\exp(\mathbf{w}_k^\top \mathbf{x}_i)}{\sum_{j=1}^{K} \exp(\mathbf{w}_j^\top \mathbf{x}_i)} = \frac{\exp(-\mathbf{w}_k^\top \mathbf{x}_i)}{\sum_{j=1}^{K} \exp(-\mathbf{w}_j^\top \mathbf{x}_i)}.$$

Regressão logística multiclasse

- A função softmax para a k-ésima classe pode ser denotada por:

$$\mathcal{S}_k(\mathbf{x}_i, \mathbf{W}) = \frac{\exp(\mathbf{w}_k^\top \mathbf{x}_i)}{\sum_{j=1}^{K} \exp(\mathbf{w}_j^\top \mathbf{x}_i)} = \frac{\exp(-\mathbf{w}_k^\top \mathbf{x}_i)}{\sum_{j=1}^{K} \exp(-\mathbf{w}_j^\top \mathbf{x}_i)}.$$

- Caso os parâmetros sejam divididos pela constante T (*temperatura*), se $T \to 0$, teríamos a função *máximo*:

$$\mathcal{S}_k(\mathbf{x}_i, \mathbf{W}/T) = \begin{cases} 1, & \text{se } k = \arg\max_j \mathbf{w}_j^\top \mathbf{x}_i \\ 0, & \text{caso contrário} \end{cases}.$$

- Para valores de T maiores, a função se tornaria mais uniforme.

Regressão logística multiclasse

- A função softmax para a k-ésima classe pode ser denotada por:

$$\mathcal{S}_k(\mathbf{x}_i, \mathbf{W}) = \frac{\exp(\mathbf{w}_k^\top \mathbf{x}_i)}{\sum_{j=1}^{K} \exp(\mathbf{w}_j^\top \mathbf{x}_i)} = \frac{\exp(-\mathbf{w}_k^\top \mathbf{x}_i)}{\sum_{j=1}^{K} \exp(-\mathbf{w}_j^\top \mathbf{x}_i)}.$$

- Caso os parâmetros sejam divididos pela constante T (*temperatura*), se $T \to 0$, teríamos a função *máximo*:

$$\mathcal{S}_k(\mathbf{x}_i, \mathbf{W}/T) = \begin{cases} 1, & \text{se } k = \arg\max_j \mathbf{w}_j^\top \mathbf{x}_i \\ 0, & \text{caso contrário} \end{cases}.$$

- Para valores de T maiores, a função se tornaria mais uniforme.
- Note que $\mathcal{S}_k(\mathbf{x}_i, \mathbf{W}/T)$ tem o mesmo formato da distribuição de Boltzmann (ou de Gibbs):

$$p_j \propto \exp\left(-\frac{E_j}{k_B T}\right),$$

em que p_j é a probabilidade do sistema estar no estado j, E_j é a energia do j-ésimo estado e k_B é a constante de Boltzmann.

O truque do log-sum-exp

- Podemos precisar calcular o logaritmo da função softmax:

$$\log p(y_{ik}|\mathbf{x}_i, \mathbf{W}) = \log \frac{\exp(\mathbf{w}_k^\top \mathbf{x}_i)}{\sum_{j=1}^{K} \exp(\mathbf{w}_j^\top \mathbf{x}_i)}$$

$$= \mathbf{w}_k^\top \mathbf{x}_i - \underbrace{\log \sum_{j=1}^{K} \exp(\mathbf{w}_j^\top \mathbf{x}_i)}_{\text{LSE}}$$

O truque do log-sum-exp

- Podemos precisar calcular o logaritmo da função softmax:

$$\log p(y_{ik}|\mathbf{x}_i, \mathbf{W}) = \log \frac{\exp(\mathbf{w}_k^\top \mathbf{x}_i)}{\sum_{j=1}^{K} \exp(\mathbf{w}_j^\top \mathbf{x}_i)}$$

$$= \mathbf{w}_k^\top \mathbf{x}_i - \underbrace{\log \sum_{j=1}^{K} \exp(\mathbf{w}_j^\top \mathbf{x}_i)}_{\text{LSE}}$$

- Os termos do somatório podem resultar em overflow. Optamos por calcular a seguinte expressão, mais estável numericamente:

$$\text{LSE} = \log \left(\sum_{h=1}^{K} \exp(\mathbf{w}_j^\top \mathbf{x}_i - C) \right) + C,$$

em que usualmente escolhemos $C = \max_j(\mathbf{w}_j^\top \mathbf{x}_i)$.

OBS.: $\log(e^a + e^b) = \log(e^b(e^a/e^b + e^0)) = \log(e^{a-b} + e^0) + b$.

Entropia cruzada - visão alternativa

- Buscamos minimizar a discrepância entre a distribuição empírica dos dados $p_{\mathcal{D}}(\mathbf{y}|\mathbf{x})$ e a distribuição do modelo $p_{\mathbf{w}}(\mathbf{y}|\mathbf{x})$.

Entropia cruzada - visão alternativa

- Buscamos minimizar a discrepância entre a distribuição empírica dos dados $p_{\mathcal{D}}(\mathbf{y}|\mathbf{x})$ e a distribuição do modelo $p_{\mathbf{w}}(\mathbf{y}|\mathbf{x})$.
- **Divergência de Kullback-Leibler (KL)**: quantifica estatisticamente a diferença entre duas distribuições:

$$\begin{aligned}
\mathrm{KL}(p_{\mathcal{D}}(\mathbf{y}|\mathbf{x})||p_{\mathbf{w}}(\mathbf{y}|\mathbf{x})) &= \sum_i p_{\mathcal{D}}(\mathbf{y}_i|\mathbf{x}_i) \log \frac{p_{\mathcal{D}}(\mathbf{y}_i|\mathbf{x}_i)}{p_{\mathbf{w}}(\mathbf{y}_i|\mathbf{x}_i)} \\
&= \sum_i p_{\mathcal{D}}(\mathbf{y}_i|\mathbf{x}_i) \log p_{\mathcal{D}}(\mathbf{y}_i|\mathbf{x}_i) - \sum_i p_{\mathcal{D}}(\mathbf{y}_i|\mathbf{x}_i) \log p_{\mathbf{w}}(\mathbf{y}_i|\mathbf{x}_i) \\
&= -\mathcal{H}(p_{\mathcal{D}}(\mathbf{y})) + \mathcal{H}(p_{\mathcal{D}}(\mathbf{y}|\mathbf{x}), p_{\mathbf{w}}(\mathbf{y}|\mathbf{x})).
\end{aligned}$$

Entropia cruzada - visão alternativa

- Buscamos minimizar a discrepância entre a distribuição empírica dos dados $p_{\mathcal{D}}(\mathbf{y}|\mathbf{x})$ e a distribuição do modelo $p_{\mathbf{w}}(\mathbf{y}|\mathbf{x})$.
- **Divergência de Kullback-Leibler (KL)**: quantifica estatisticamente a diferença entre duas distribuições:

$$\begin{aligned}\mathrm{KL}(p_{\mathcal{D}}(\mathbf{y}|\mathbf{x})||p_{\mathbf{w}}(\mathbf{y}|\mathbf{x})) &= \sum_i p_{\mathcal{D}}(\mathbf{y}_i|\mathbf{x}_i) \log \frac{p_{\mathcal{D}}(\mathbf{y}_i|\mathbf{x}_i)}{p_{\mathbf{w}}(\mathbf{y}_i|\mathbf{x}_i)} \\ &= \sum_i p_{\mathcal{D}}(\mathbf{y}_i|\mathbf{x}_i) \log p_{\mathcal{D}}(\mathbf{y}_i|\mathbf{x}_i) - \sum_i p_{\mathcal{D}}(\mathbf{y}_i|\mathbf{x}_i) \log p_{\mathbf{w}}(\mathbf{y}_i|\mathbf{x}_i) \\ &= -\mathcal{H}(p_{\mathcal{D}}(\mathbf{y})) + \mathcal{H}(p_{\mathcal{D}}(\mathbf{y}|\mathbf{x}), p_{\mathbf{w}}(\mathbf{y}|\mathbf{x})).\end{aligned}$$

- Como a entropia $\mathcal{H}(p_{\mathcal{D}}(\mathbf{y}|\mathbf{x}))$ não depende dos parâmetros $\mathbf{w}$, minimizar o KL em relação a $\mathbf{w}$ equivale a minimizar a entropia cruzada $\mathcal{H}(p_{\mathcal{D}}(\mathbf{y}|\mathbf{x}), p_{\mathbf{w}}(\mathbf{y}|\mathbf{x}))$.

Entropia cruzada - visão alternativa

- Portanto, busca-se minimizar a seguinte função custo em relação aos parâmetros $\mathbf{w}$:

$$\begin{aligned}\mathcal{H}(p_{\mathcal{D}}(\mathbf{y}|\mathbf{x}), p_{\mathbf{w}}(\mathbf{y}|\mathbf{x})) &= -\sum_i p_{\mathcal{D}}(\mathbf{y}_i|\mathbf{x}_i) \log p_{\mathbf{w}}(\mathbf{y}_i|\mathbf{x}_i) \\ &= -\mathbb{E}_{\mathbf{x},\mathbf{y}\sim p_{\mathcal{D}}}[\log p_{\mathbf{w}}(\mathbf{y}|\mathbf{x})].\end{aligned}$$

- Nota-se que a entropia cruzada é o negativo da log-verossimilhança calculada sobre os dados observados.
- Isso é verdadeiro para qualquer cenário de estimação por máxima verossimilhança (MLE), não somente classificação!

Agenda

1. Classificação binária
2. Regressão logística binária
3. Regressão logística multiclasse
4. Regressão logística via algoritmo IRLS
5. Regressão logística Bayesiana - Aproximação de Laplace
6. Tópicos adicionais
7. Referências

Algoritmo IRLS

- Por causa da não-linearidade da função sigmoide, não há uma solução analítica para a regressão logística.

Algoritmo IRLS

- Por causa da não-linearidade da função sigmoide, não há uma solução analítica para a regressão logística.
- **IRLS (iterative reweighted least squares)**: Aplicação iterativa do algoritmo de Newton-Raphson:

$$\mathbf{w}_t = \mathbf{w}_{t-1} - (\nabla\nabla\mathcal{J}(\mathbf{w}_{t-1}))^{-1}\nabla\mathcal{J}(\mathbf{w}_{t-1}),$$

em que $\mathcal{J}(\mathbf{w})$ é a função custo, $\nabla\mathcal{J}(\mathbf{w})$ é o seu gradiente em relação aos parâmetros $\mathbf{w}$ e $\nabla\nabla\mathcal{J}(\mathbf{w})$ é a sua Hessiana.

Algoritmo IRLS

- Computamos o gradiente e a Hessiana da função custo $\mathcal{J}(\mathbf{w})$:

$$\mathcal{J}(\mathbf{w}) = -\sum_{i=1}^{N} \left[y_i \log \sigma(\mathbf{w}^\top \mathbf{x}_i) + (1 - y_i) \log(1 - \sigma(\mathbf{w}^\top \mathbf{x}_i)) \right],$$

$$\nabla \mathcal{J}(\mathbf{w}) = -\sum_{i=1}^{N} (y_i - \sigma(\mathbf{w}^\top \mathbf{x}_i)) \mathbf{x}_i = -\mathbf{X}^\top (\mathbf{y} - \sigma(\mathbf{X}\mathbf{w})),$$

$$\nabla \nabla \mathcal{J}(\mathbf{w}) = \nabla \left[-\sum_{i=1}^{N} \left(\mathbf{x}_i y_i - \mathbf{x}_i \sigma(\mathbf{w}^\top \mathbf{x}_i) \right) \right]$$

$$= \sum_{i=1}^{N} \mathbf{x}_i \sigma(\mathbf{w}^\top \mathbf{x}_i)(1 - \sigma(\mathbf{w}^\top \mathbf{x}_i)) \mathbf{x}_i^\top = \mathbf{X}^\top \mathbf{R} \mathbf{X},$$

$$\mathbf{R} = \mathrm{diag}(R_{11}, \ldots, R_{NN}),$$

$$R_{ii} = \sigma(\mathbf{w}^\top \mathbf{x}_i)(1 - \sigma(\mathbf{w}^\top \mathbf{x}_i)).$$

Algoritmo IRLS

- Os parâmetros $\mathbf{w}$ são atualizados via IRLS da seguinte maneira:

$$\begin{aligned}
\mathbf{w}_t &= \mathbf{w}_{t-1} - (\nabla\nabla\mathcal{J}(\mathbf{w}_{t-1}))^{-1}\nabla\mathcal{J}(\mathbf{w}_{t-1}) \\
&= \mathbf{w}_{t-1} + (\mathbf{X}^\top\mathbf{R}_{t-1}\mathbf{X})^{-1}\mathbf{X}^\top(\mathbf{y} - \sigma(\mathbf{X}\mathbf{w}_{t-1})) \\
&= (\mathbf{X}^\top\mathbf{R}_{t-1}\mathbf{X})^{-1}\left[\mathbf{X}^\top\mathbf{R}_{t-1}\mathbf{X}\mathbf{w}_{t-1} + \mathbf{X}^\top(\mathbf{y} - \sigma(\mathbf{X}\mathbf{w}_{t-1}))\right] \\
&= (\mathbf{X}^\top\mathbf{R}_{t-1}\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{R}_{t-1}\mathbf{z}_{t-1},
\end{aligned}$$

em que:

$$\begin{aligned}
\mathbf{R}_{t-1} &= \mathrm{diag}([R_{t-1}]_{11}, \ldots, [R_{t-1}]_{NN}), \\
[R_{t-1}]_{ii} &= \sigma(\mathbf{w}_{t-1}^\top\mathbf{x}_i)(1 - \sigma(\mathbf{w}_{t-1}^\top\mathbf{x}_i)), \\
\mathbf{z}_{t-1} &= \mathbf{X}\mathbf{w}_{t-1} + \mathbf{R}_{t-1}^{-1}(\mathbf{y} - \sigma(\mathbf{X}\mathbf{w}_{t-1})).
\end{aligned}$$

- Pode ser extrapolado para o caso multiclasse (Murphy, pgs. 252-254).

Algoritmo IRLS - Solução MAP

- Considerando uma priori $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{m}_0, \mathbf{S}_0)$, temos:

$$\mathcal{J}_{\text{MAP}}(\mathbf{w}) = \mathcal{J}(\mathbf{w}) - \log \mathcal{N}(\mathbf{w}|\mathbf{m}_0, \mathbf{S}_0).$$

- O gradiente e a Hessiana modificados serão dados por:

$$\nabla \mathcal{J}_{\text{MAP}}(\mathbf{w}) = \nabla \mathcal{J}(\mathbf{w}) + \mathbf{S}_0^{-1}(\mathbf{w} - \mathbf{m}_0),$$
$$\nabla\nabla \mathcal{J}_{\text{MAP}}(\mathbf{w}) = \nabla\nabla \mathcal{J}(\mathbf{w}) + \mathbf{S}_0^{-1}.$$

- A solução iterativa MAP do IRLS é computada por:

$$\begin{aligned}\mathbf{w}_t &= \mathbf{w}_{t-1} - (\nabla\nabla \mathcal{J}_{\text{MAP}}(\mathbf{w}_{t-1}))^{-1} \nabla \mathcal{J}_{\text{MAP}}(\mathbf{w}_{t-1}) \\ &= \mathbf{w}_{t-1} + \mathbf{A}^{-1}[\mathbf{X}^\top(\mathbf{y} - \sigma(\mathbf{X}\mathbf{w}_{t-1})) - \mathbf{S}_0^{-1}(\mathbf{w}_{t-1} - \mathbf{m}_0)],\end{aligned}$$

em que:

$$\mathbf{A} = \mathbf{X}^\top \mathbf{R}_{t-1} \mathbf{X} + \mathbf{S}_0^{-1},$$
$$\mathbf{R}_{t-1} = \text{diag}([R_{t-1}]_{11}, \ldots, [R_{t-1}]_{NN}),$$
$$[R_{t-1}]_{ii} = \sigma(\mathbf{w}_{t-1}^\top \mathbf{x}_i)(1 - \sigma(\mathbf{w}_{t-1}^\top \mathbf{x}_i)).$$

Algoritmo IRLS - Solução MAP

Resumo do algoritmo

- Passo de estimação
  1. Defina a partir de conhecimentos/experimentos anteriores:
     - $\rightarrow$ os momentos da priori $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{m}_0, \mathbf{S}_0)$;
     - $\rightarrow$ o valor inicial de $\mathbf{w}_0 \in \mathbb{R}^D$.
  2. A partir dos dados $\mathcal{D} = (\mathbf{X}, \mathbf{y})$, repita até convergir:

$$\mathbf{w}_t = \mathbf{w}_{t-1} + \mathbf{A}^{-1}[\mathbf{X}^\top(\mathbf{y} - \sigma(\mathbf{X}\mathbf{w}_{t-1})) - \mathbf{S}_0^{-1}(\mathbf{w}_{t-1} - \mathbf{m}_0)],$$

em que:

$$\mathbf{A} = \mathbf{X}^\top \mathbf{R}_{t-1} \mathbf{X} + \mathbf{S}_0^{-1},$$
$$\mathbf{R}_{t-1} = \mathrm{diag}([R_{t-1}]_{11}, \ldots, [R_{t-1}]_{NN}),$$
$$[R_{t-1}]_{ii} = \sigma(\mathbf{w}_{t-1}^\top \mathbf{x}_i)(1 - \sigma(\mathbf{w}_{t-1}^\top \mathbf{x}_i)).$$

  3. Retorne os parâmetros estimados $\hat{\mathbf{w}}$.
- Passo de predição
  1. Dado um padrão $\mathbf{x}_*$, retorne a predição:

$$p(y_* = 1|\mathbf{x}_*) = \sigma(\hat{\mathbf{w}}^\top \mathbf{x}_*).$$

Agenda

1. Classificação binária
2. Regressão logística binária
3. Regressão logística multiclasse
4. Regressão logística via algoritmo IRLS
5. Regressão logística Bayesiana - Aproximação de Laplace
6. Tópicos adicionais
7. Referências

Regressão logística Bayesiana

- Considere um modelo de regressão logística binária:

$$p(\mathbf{y}|\mathbf{X},\mathbf{w}) = \prod_{i=1}^{N} \sigma(\mathbf{w}^\top \mathbf{x}_i)^{y_i}(1-\sigma(\mathbf{w}^\top \mathbf{x}_i))^{1-y_i}, \quad y_i \in \{0,1\},$$

$$= \prod_{i=1}^{N} \sigma_i^{y_i}(1-\sigma_i^{1-y_i}),$$

em que $\sigma_i = \sigma(\mathbf{w}^\top \mathbf{x}_i) = \dfrac{1}{1+\exp(-\mathbf{w}^\top \mathbf{x}_i)}$.

- Considere uma priori Gaussiana para o vetor de parâmetros $\mathbf{w}$:

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{m}_0, \mathbf{S}_0).$$

- Após a observação dos dados $\mathcal{D} = (\mathbf{X}, \mathbf{y})$, como calcular a posteriori $p(\mathbf{w}|\mathcal{D}) = \frac{p(\mathcal{D}|\mathbf{w})p(\mathbf{w})}{p(\mathcal{D})}$?

Regressão logística Bayesiana

- Considere um modelo de regressão logística binária:

$$p(\mathbf{y}|\mathbf{X},\mathbf{w}) = \prod_{i=1}^{N} \sigma(\mathbf{w}^\top \mathbf{x}_i)^{y_i}(1-\sigma(\mathbf{w}^\top \mathbf{x}_i))^{1-y_i}, \quad y_i \in \{0,1\},$$

$$= \prod_{i=1}^{N} \sigma_i^{y_i}(1-\sigma_i^{1-y_i}),$$

em que $\sigma_i = \sigma(\mathbf{w}^\top \mathbf{x}_i) = \dfrac{1}{1+\exp(-\mathbf{w}^\top \mathbf{x}_i)}$.

- Considere uma priori Gaussiana para o vetor de parâmetros $\mathbf{w}$:

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{m}_0, \mathbf{S}_0).$$

- Após a observação dos dados $\mathcal{D} = (\mathbf{X}, \mathbf{y})$, como calcular a posteriori $p(\mathbf{w}|\mathcal{D}) = \frac{p(\mathcal{D}|\mathbf{w})p(\mathbf{w})}{p(\mathcal{D})}$? Sem solução analítica!

Aproximação de Laplace

- **Ideia:** Aproximar uma distribuição complexa por uma Gaussiana.

Aproximação de Laplace

- **Ideia:** Aproximar uma distribuição complexa por uma Gaussiana.
- **Ideia:** A média será a moda da posteriori original e a matriz de covariância será a inversa da Hessiana do negativo da log-posteriori.

Aproximação de Laplace

- **Ideia:** Aproximar uma distribuição complexa por uma Gaussiana.
- **Ideia:** A média será a moda da posteriori original e a matriz de covariância será a inversa da Hessiana do negativo da log-posteriori. (calma, vamos justificar!)

Aproximação de Laplace

- **Ideia:** Aproximar uma distribuição complexa por uma Gaussiana.
- **Ideia:** A média será a moda da posteriori original e a matriz de covariância será a inversa da Hessiana do negativo da log-posteriori. (calma, vamos justificar!)
- Voltando à posteriori buscada:

$$p(\mathbf{w}|\mathcal{D}) = \frac{p(\mathcal{D}|\mathbf{w})p(\mathbf{w})}{p(\mathcal{D})}$$

$$\log p(\mathbf{w}|\mathcal{D}) = \underbrace{\log p(\mathcal{D}|\mathbf{w}) + \log p(\mathbf{w})}_{\Psi(\mathbf{w})} - \log p(\mathcal{D}).$$

Aproximação de Laplace

- **Ideia:** Aproximar uma distribuição complexa por uma Gaussiana.
- **Ideia:** A média será a moda da posteriori original e a matriz de covariância será a inversa da Hessiana do negativo da log-posteriori. (calma, vamos justificar!)
- Voltando à posteriori buscada:

$$p(\mathbf{w}|\mathcal{D}) = \frac{p(\mathcal{D}|\mathbf{w})p(\mathbf{w})}{p(\mathcal{D})}$$

$$\log p(\mathbf{w}|\mathcal{D}) = \underbrace{\log p(\mathcal{D}|\mathbf{w}) + \log p(\mathbf{w})}_{\Psi(\mathbf{w})} - \log p(\mathcal{D}).$$

- Função de energia: $E(\mathbf{w}) = -\log p(\mathcal{D}|\mathbf{w})p(\mathbf{w}) = -\Psi(\mathbf{w})$.
- Note que: $p(\mathbf{w}|\mathcal{D}) = \frac{1}{p(\mathcal{D})}\exp(-E(\mathbf{w})) = \frac{1}{p(\mathcal{D})}\exp(\Psi(\mathbf{w}))$.

Aproximação de Laplace

- **Ideia:** Aproximar uma distribuição complexa por uma Gaussiana.
- **Ideia:** A média será a moda da posteriori original e a matriz de covariância será a inversa da Hessiana do negativo da log-posteriori. (calma, vamos justificar!)
- Voltando à posteriori buscada:

$$p(\mathbf{w}|\mathcal{D}) = \frac{p(\mathcal{D}|\mathbf{w})p(\mathbf{w})}{p(\mathcal{D})}$$

$$\log p(\mathbf{w}|\mathcal{D}) = \underbrace{\log p(\mathcal{D}|\mathbf{w}) + \log p(\mathbf{w})}_{\Psi(\mathbf{w})} - \log p(\mathcal{D}).$$

- Função de energia: $E(\mathbf{w}) = -\log p(\mathcal{D}|\mathbf{w})p(\mathbf{w}) = -\Psi(\mathbf{w})$.
- Note que: $p(\mathbf{w}|\mathcal{D}) = \frac{1}{p(\mathcal{D})}\exp(-E(\mathbf{w})) = \frac{1}{p(\mathcal{D})}\exp(\Psi(\mathbf{w}))$.
- A média da aproximação será a solução MAP $\hat{\mathbf{w}}$ usual:

$$\hat{\mathbf{w}} = \arg_{\mathbf{w}} \max \Psi(\mathbf{w}) = \arg_{\mathbf{w}} \min E(\mathbf{w}).$$

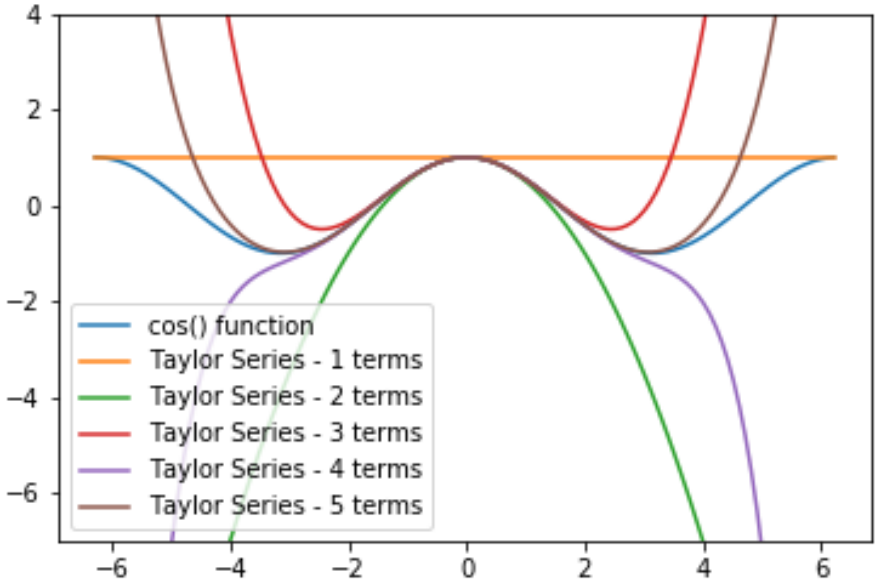
Aproximação de Laplace

Teorema de Taylor para aproximação de funções

- Uma função real k vezes diferenciável em a pode ser aproximada por um polinômio de Taylor de ordem k:

$$f(x) \approx f(a) + f'(a)(x-a) + \frac{f''(a)}{2!}(x-a)^2 + \ldots + \frac{f^{(k)}(a)}{k!}(x-a)^k.$$

- Por conveniência, podemos truncar a série em uma ordem $< k$.



Aproximação de Laplace

- Escolhemos uma expansão de Taylor de segunda ordem (quadrática) para aproximar $\Psi(\mathbf{w})$ em torno de $\hat{\mathbf{w}}$:

$$\begin{aligned}\Psi(\mathbf{w}) &\approx \Psi(\hat{\mathbf{w}}) + (\mathbf{w}-\hat{\mathbf{w}})^\top \Psi'(\hat{\mathbf{w}}) + \frac{1}{2}(\mathbf{w}-\hat{\mathbf{w}})^\top \Psi''(\hat{\mathbf{w}})(\mathbf{w}-\hat{\mathbf{w}}) \\ &\approx \Psi(\hat{\mathbf{w}}) + \frac{1}{2}(\mathbf{w}-\hat{\mathbf{w}})^\top \Psi''(\hat{\mathbf{w}})(\mathbf{w}-\hat{\mathbf{w}}),\end{aligned}$$

em que $\Psi'(\hat{\mathbf{w}}) = 0$, pois $\hat{\mathbf{w}}$ é um máximo de $\Psi(\mathbf{w})$.

Aproximação de Laplace

- Podemos reescrever a aproximação:

$$\Psi(\mathbf{w}) \approx \Psi(\hat{\mathbf{w}}) - \frac{1}{2}(\mathbf{w} - \hat{\mathbf{w}})^\top \mathbf{H}(\mathbf{w} - \hat{\mathbf{w}}),$$

$$\text{em que } \mathbf{H} = -\Psi''(\hat{\mathbf{w}}) = -\nabla\nabla\Psi(\hat{\mathbf{w}}) = \mathbf{X}^\top \mathbf{R}\mathbf{X} + \mathbf{S}_0^{-1}.$$

Aproximação de Laplace

- Podemos reescrever a aproximação:

$$\Psi(\mathbf{w}) \approx \Psi(\hat{\mathbf{w}}) - \frac{1}{2}(\mathbf{w} - \hat{\mathbf{w}})^\top \mathbf{H}(\mathbf{w} - \hat{\mathbf{w}}),$$

$$\text{em que } \mathbf{H} = -\Psi''(\hat{\mathbf{w}}) = -\nabla\nabla\Psi(\hat{\mathbf{w}}) = \mathbf{X}^\top \mathbf{R}\mathbf{X} + \mathbf{S}_0^{-1}.$$

- Aplicamos uma exponencial em ambos os lados:

$$\begin{aligned} p(\mathbf{w}|\mathcal{D}) &\overset{\propto}{\approx} \exp(\Psi(\mathbf{w})) \\ &\overset{\propto}{\approx} \exp(\Psi(\hat{\mathbf{w}})) \exp\left(-\frac{1}{2}(\mathbf{w} - \hat{\mathbf{w}})^\top \mathbf{H}(\mathbf{w} - \hat{\mathbf{w}})\right), \\ &\approx \mathcal{N}(\mathbf{w}|\hat{\mathbf{w}}, \mathbf{H}^{-1}). \end{aligned}$$

Aproximação de Laplace

- Podemos também aproximar a evidência:

$$
\begin{aligned}
\log p(\mathcal{D}) &= \log \int p(\mathcal{D}|\mathbf{w})p(\mathbf{w})\mathrm{d}\mathbf{w} \\
&\approx \log \int \exp(\Psi(\mathbf{w}))\mathrm{d}\mathbf{w} \\
&\approx \Psi(\hat{\mathbf{w}}) + \log \int \exp\left(-\frac{1}{2}(\mathbf{w}-\hat{\mathbf{w}})^\top \mathbf{H}(\mathbf{w}-\hat{\mathbf{w}})\right)\mathrm{d}\mathbf{w} \\
&\approx \log p(\mathcal{D}|\hat{\mathbf{w}}) + \log p(\hat{\mathbf{w}}) + \log \frac{(2\pi)^{D/2}}{|\mathbf{H}|^{1/2}} \\
&\approx \log p(\mathcal{D}|\hat{\mathbf{w}}) + \log p(\hat{\mathbf{w}}) + \frac{D}{2}\log 2\pi - \frac{1}{2}\log|\mathbf{H}|,
\end{aligned}
$$

em que D é a dimensão de $\mathbf{w}$.

Bayesian Information Criterion (BIC)

- Repetimos a evidência aproximada abaixo:

$$\log p(\mathcal{D}) \approx \log p(\mathcal{D}|\hat{\mathbf{w}}) + \log p(\hat{\mathbf{w}}) + \frac{D}{2}\log 2\pi - \frac{1}{2}\log|\mathbf{H}|.$$

- O índice BIC para comparação de modelos pode ser obtido após algumas considerações:
  - → Ignorar o termo constante;
  - → Usar priori uniforme para os parâmetros, o que torna $\hat{\mathbf{w}} = \mathbf{w}_{\text{ML}}$;
  - → Seja $\mathbf{H} = \sum_{i=1}^{N} \mathbf{H}_i$, em que $\mathbf{H}_i = -\nabla\nabla \log p(\mathcal{D}_i|\mathbf{w})$.
    Aproximando $\mathbf{H}_i = \hat{\mathbf{H}}$, podemos aproximar o termo $\log|\mathbf{H}|$:

$$\log|\mathbf{H}| \approx \log|N\hat{\mathbf{H}}| = \log(N^D|\hat{\mathbf{H}}|) = D\log N + \log|\hat{\mathbf{H}}|.$$

    O termo $\log|\hat{\mathbf{H}}|$ não depende de N e será dominado para N grande, podendo ser desprezado.
- A partir dos pontos acima o índice BIC é dado por:

$$\text{BIC} = \log p(\mathcal{D}|\mathbf{w}_{\text{ML}}) - \frac{D}{2}\log N.$$

Bayesian Information Criterion (BIC)

- Índice BIC para regressão linear/logística:

$$\text{BIC} = \log p(\mathcal{D}|\mathbf{w}_{\text{ML}}) - \frac{D}{2} \log N.$$

- De maneira mais geral, podemos considerar os graus de liberdade $\text{dof}(\mathbf{w})$ do modelo:

$$\text{BIC} = \log p(\mathcal{D}|\mathbf{w}_{\text{ML}}) - \frac{\text{dof}(\mathbf{w})}{2} \log N.$$

- Outro índice popular é o **Akaike Information Criterion (AIC)**:

$$\text{AIC} = \log p(\mathcal{D}|\mathbf{w}_{\text{ML}}) - \text{dof}(\mathbf{w}).$$

Regressão Logística Bayesiana

- Dada uma entrada $\mathbf{x}_*$, buscamos uma distribuição preditiva:

$$p(y_* = 1|\mathbf{x}_*, \mathcal{D}) = \int p(y_*|\mathbf{x}_*, \mathbf{w}) p(\mathbf{w}|\mathcal{D}) \mathrm{d}\mathbf{w}$$
$$\approx \int \sigma(\mathbf{w}^\top \mathbf{x}_*) \mathcal{N}(\mathbf{w}|\hat{\mathbf{w}}, \mathbf{H}^{-1}) \mathrm{d}\mathbf{w},$$
$$p(y_* = 0|\mathbf{x}_*, \mathcal{D}) = 1 - p(y_* = 1|\mathbf{x}_*, \mathcal{D}).$$

- A matriz $\mathbf{H} = -\nabla\nabla\Psi(\hat{\mathbf{w}})$ será dada por:

$$\mathbf{H} = -\nabla\nabla[\log p(\mathcal{D}|\mathbf{w}) + \log p(\mathbf{w})]|_{\hat{\mathbf{w}}} = \mathbf{X}^\top \hat{\mathbf{R}} \mathbf{X} + \mathbf{S}_0^{-1},$$
$$\hat{\mathbf{R}} = \mathrm{diag}(\hat{R}_{11}, \ldots, \hat{R}_{NN}), \quad \hat{R}_{ii} = \sigma(\hat{\mathbf{w}}^\top \mathbf{x}_i)(1 - \sigma(\hat{\mathbf{w}}^\top \mathbf{x}_i)).$$

- A distribuição preditiva não é analítica e precisa ser aproximada:
  - $\rightarrow$ Aproximação de Monte Carlo;
  - $\rightarrow$ Aproximação probit.

Regressão Logística Bayesiana - Monte Carlo

- Seguindo uma aproximação de **Monte Carlo**:

$$p(y_* = 1|\mathbf{x}_*, \mathcal{D}) \approx \int \sigma(\mathbf{w}^\top \mathbf{x}_*)\mathcal{N}(\mathbf{w}|\hat{\mathbf{w}}, \mathbf{H}^{-1})\mathrm{d}\mathbf{w},$$

$$= \frac{1}{S}\sum_{s=1}^{S} \sigma(\mathbf{w}_s^\top \mathbf{x}_*),$$

$$\mathbf{w}_s \sim \mathcal{N}(\mathbf{w}|\hat{\mathbf{w}}, \mathbf{H}^{-1}).$$

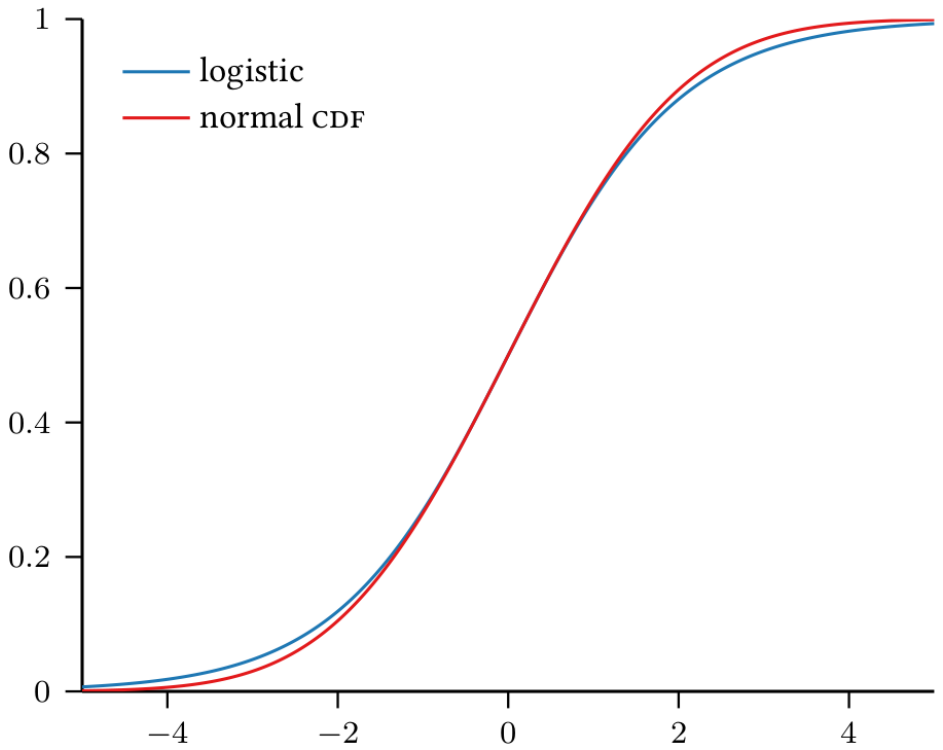
- Gerar amostras independentes de uma Gaussiana multivariada pode ser feito diretamente via pacotes estatísticos.
- Podemos reaproveitar as amostras $\mathbf{w}_s|_{s=1}^{S}$ para diferentes entradas.

Regressão Logística Bayesiana - aproximação probit

- A função logística $\sigma(z)$ pode ser aproximada pela função cumulativa (CDF) da distribuição Gaussiana normalizada:

$$\sigma(z) \approx \Phi(\lambda z), \quad \lambda = \sqrt{\pi/8},$$

$$\Phi(z) \triangleq \int_{-\infty}^{z} \mathcal{N}(z|0,1)\mathrm{d}z \quad \text{(função probit)}.$$



Regressão Logística Bayesiana - aproximação probit

- Substituímos a função logística pela função probit:

$$p(y_* = 1|\mathbf{x}_*, \mathcal{D}) \approx \int \Phi(\lambda \mathbf{w}^\top \mathbf{x}_*) \mathcal{N}(\mathbf{w}|\hat{\mathbf{w}}, \mathbf{H}^{-1}) \mathrm{d}\mathbf{w}$$

- Note que o termo $\Phi(\lambda \mathbf{w}^\top \mathbf{x}_*)$ na verdade depende de um escalar $a = \mathbf{w}^\top \mathbf{x}_*$. Por isso, a integral se torna unidimensional:

$$p(y_* = 1|\mathbf{x}_*, \mathcal{D}) \approx \int \Phi(\lambda a) \mathcal{N}(a|\mu_a, \sigma_a^2) \mathrm{d}a,$$

$$\mu_a = \hat{\mathbf{w}}^\top \mathbf{x}_*,$$

$$\sigma_a^2 = \mathbf{x}_*^\top \mathbf{H}^{-1} \mathbf{x}_*.$$

- Essa última integral possui a solução analítica abaixo:

$$p(y_* = 1|\mathbf{x}_*, \mathcal{D}) \approx \Phi\left(\frac{\mu_a}{(\lambda^{-2} + \sigma_a^2)^{1/2}}\right) = \sigma((1 + \pi\sigma_a^2/8)^{-1/2} \mu_a).$$

Regressão Logística Bayesiana

Resumo do algoritmo

- Passo de estimação
  1. Defina a partir de conhecimentos/experimentos anteriores:
     $\rightarrow$ os momentos da priori $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{m}_0, \mathbf{S}_0)$;
  2. A partir dos dados $\mathcal{D} = (\mathbf{X}, \mathbf{y})$, encontre a solução MAP para $\hat{\mathbf{w}}$ (e.g. via algoritmo IRLS).
  3. Aproxime a posteriori de $\mathbf{w}$:

$$p(\mathbf{w}|\mathcal{D}) \approx \mathcal{N}(\mathbf{w}|\hat{\mathbf{w}}, \mathbf{H}^{-1}),$$

     em que:

$$\mathbf{H} = \mathbf{X}^\top \hat{\mathbf{R}} \mathbf{X} + \mathbf{S}_0^{-1},$$
$$\hat{\mathbf{R}} = \mathrm{diag}(\hat{R}_{11}, \ldots, \hat{R}_{NN}),$$
$$\hat{R}_{ii} = \sigma(\hat{\mathbf{w}}^\top \mathbf{x}_i)(1 - \sigma(\hat{\mathbf{w}}^\top \mathbf{x}_i)).$$

  4. Retorne a posteriori aproximada $p(\mathbf{w}|\mathcal{D}) \approx \mathcal{N}(\mathbf{w}|\hat{\mathbf{w}}, \mathbf{H}^{-1})$.

Regressão Logística Bayesiana

Resumo do algoritmo

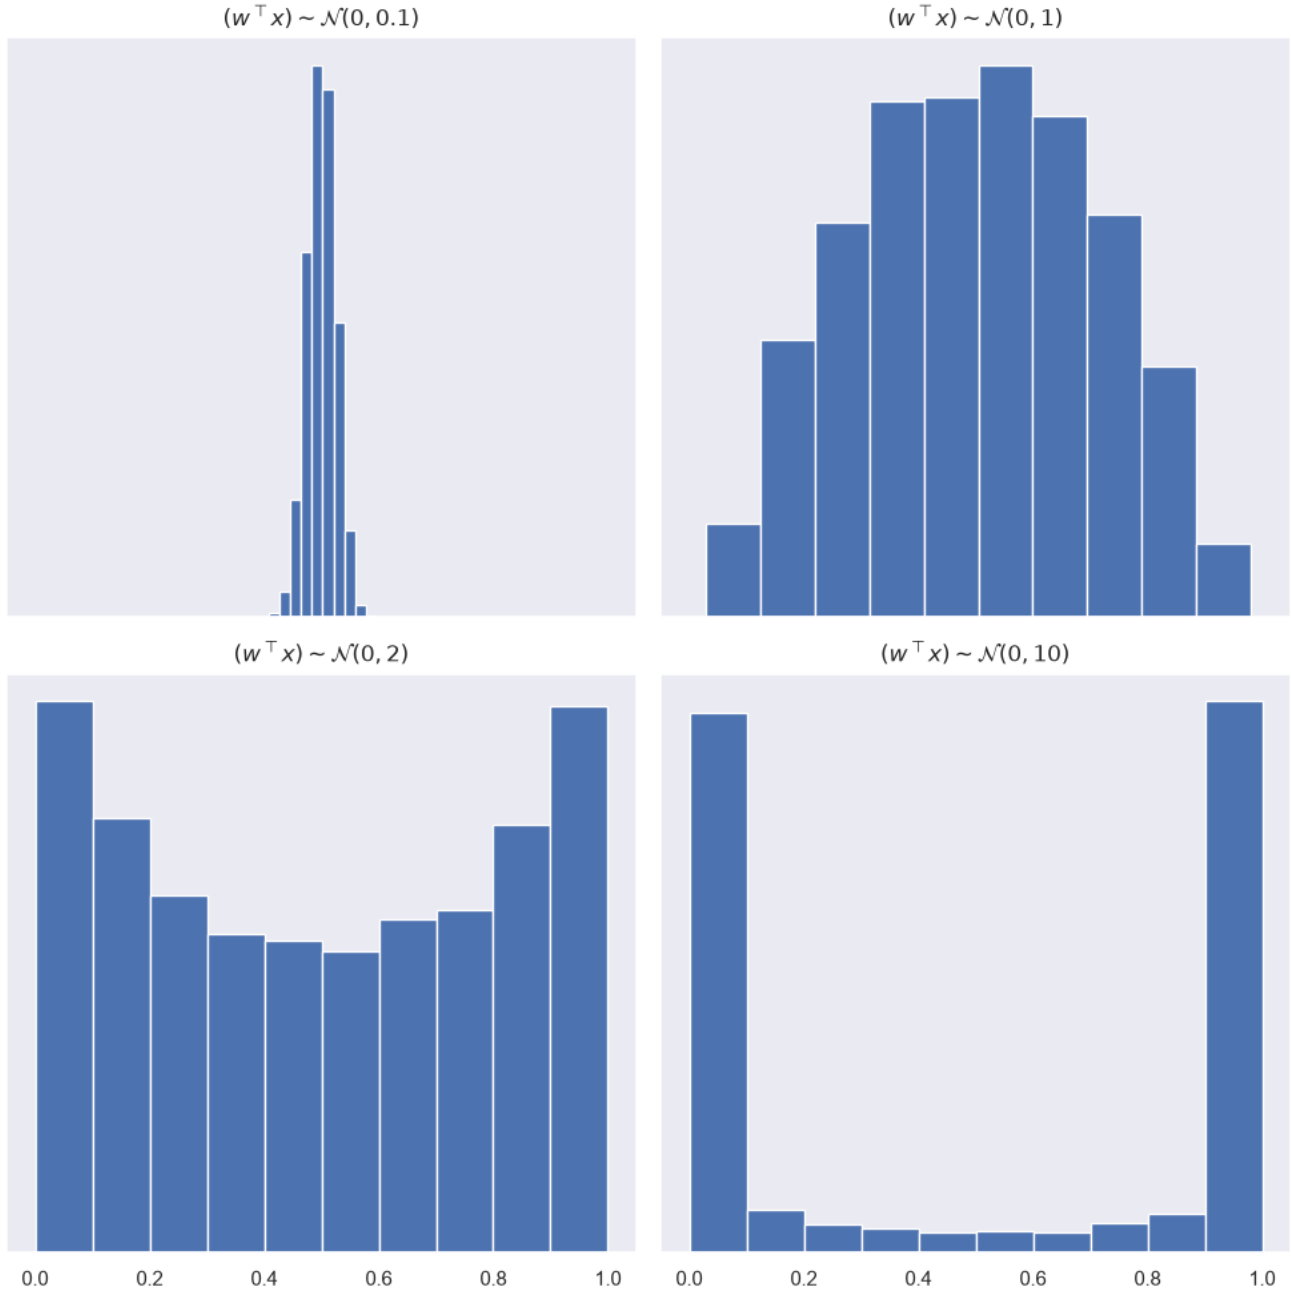
- Passo de predição
  1. Dado um padrão $\mathbf{x}_*$, retorne a distribuição preditiva:
     - → Via aproximação de Monte Carlo:

$$p(y_* = 1|\mathbf{x}_*) \approx \frac{1}{S}\sum_{s=1}^{S}\sigma(\mathbf{w}_s^\top \mathbf{x}_*),$$
$$\mathbf{w}_s \sim \mathcal{N}(\mathbf{w}|\hat{\mathbf{w}}, \mathbf{H}^{-1}).$$

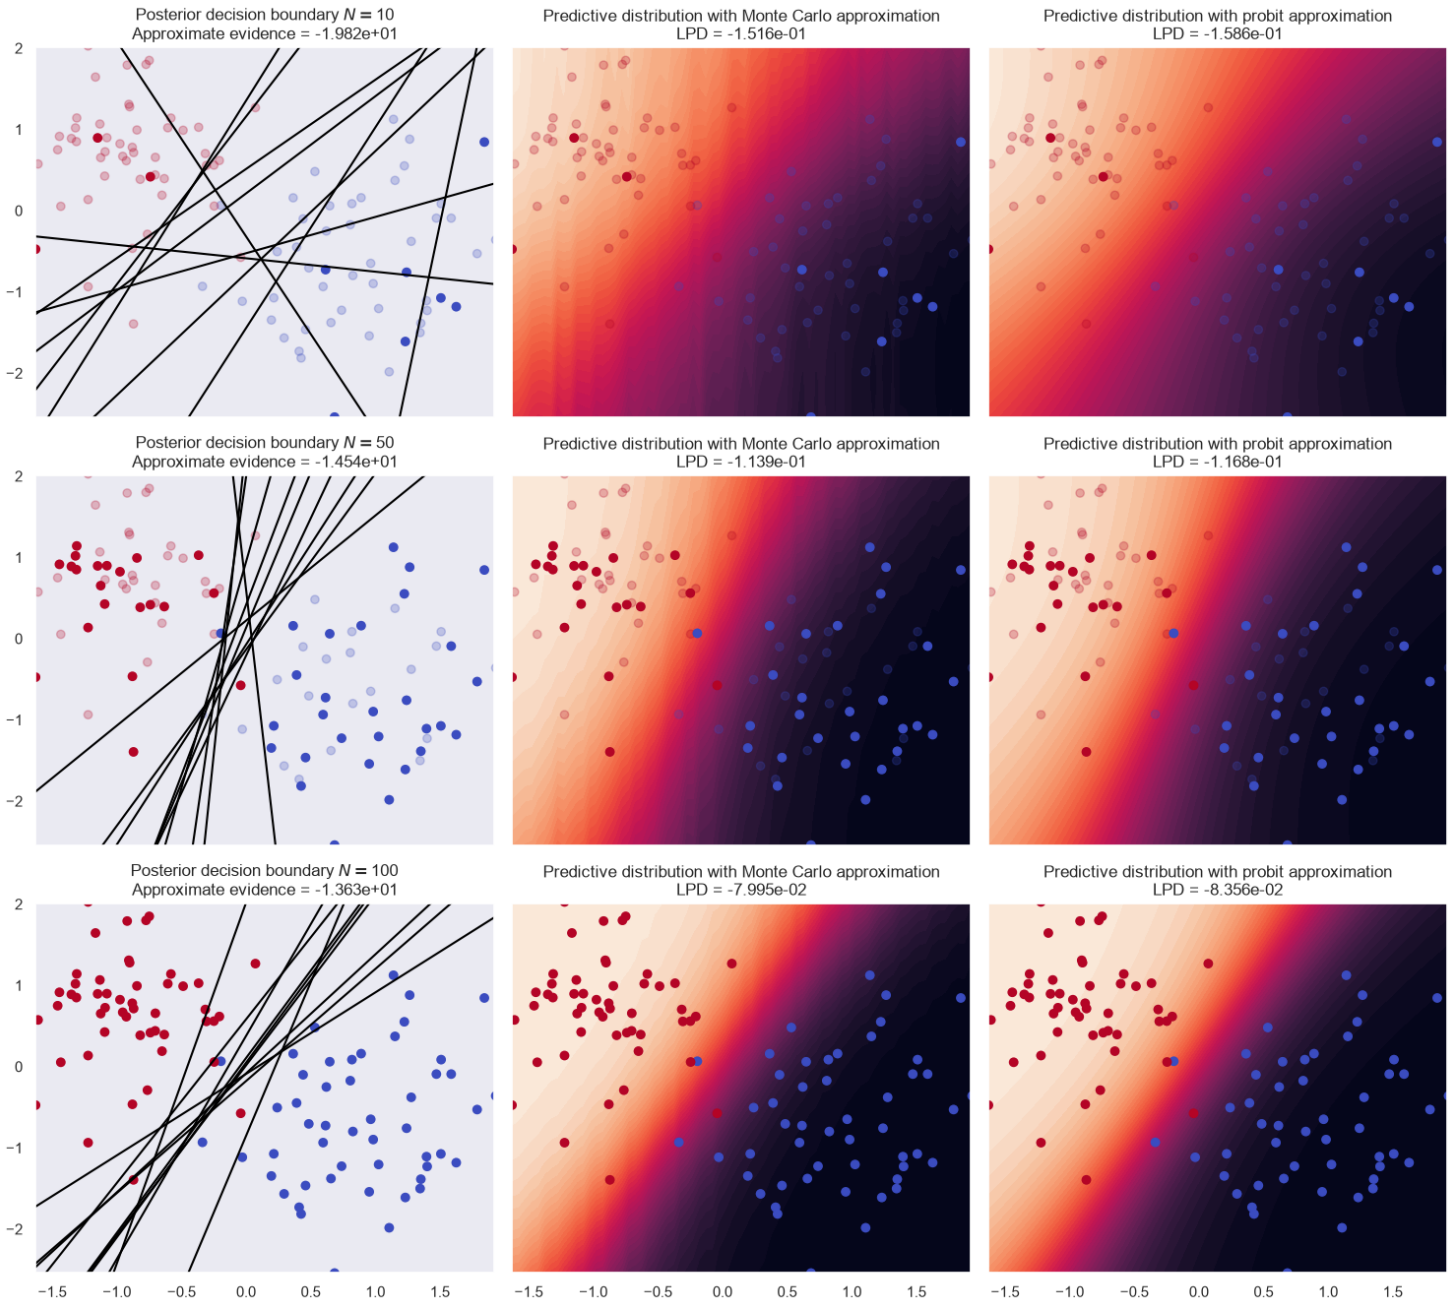
     - → Via aproximação probit:

$$p(y_* = 1|\mathbf{x}_*) \approx \sigma((1 + \pi\sigma_a^2/8)^{-1/2}\mu_a),$$
$$\mu_a = \hat{\mathbf{w}}^\top \mathbf{x}_*,$$
$$\sigma_a^2 = \mathbf{x}_*^\top \mathbf{H}^{-1}\mathbf{x}_*.$$

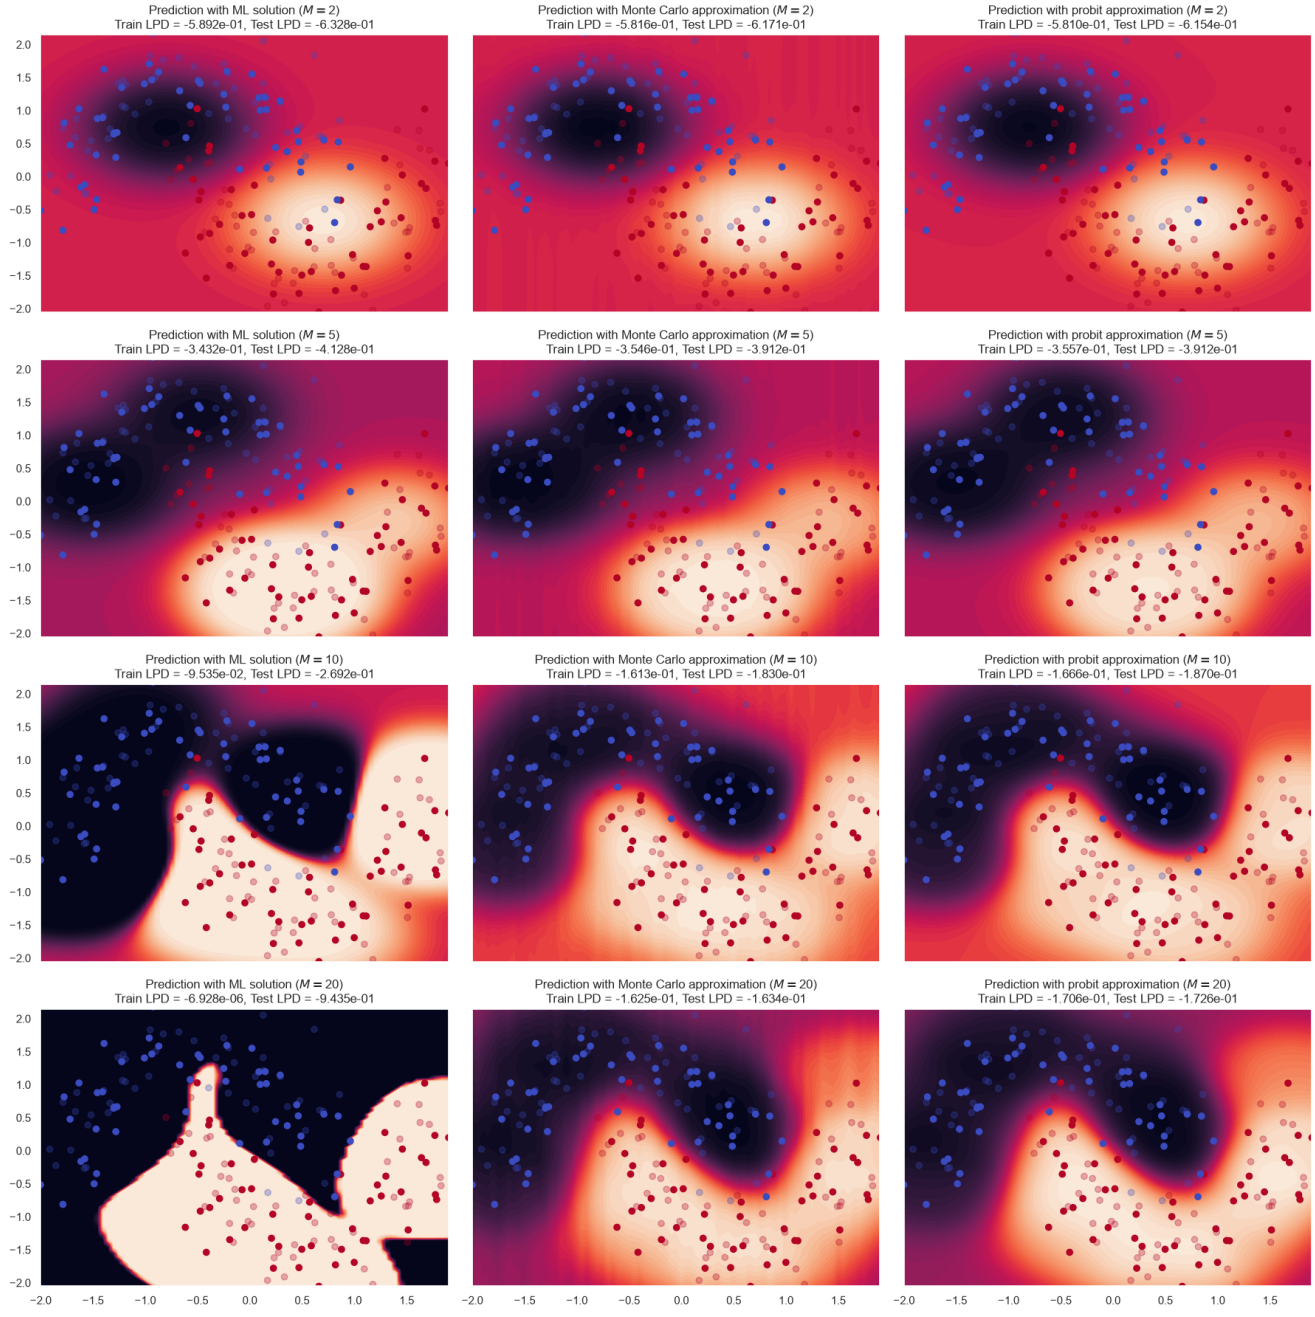
Regressão Logística Bayesiana - opções de priori



Regressão Logística Bayesiana

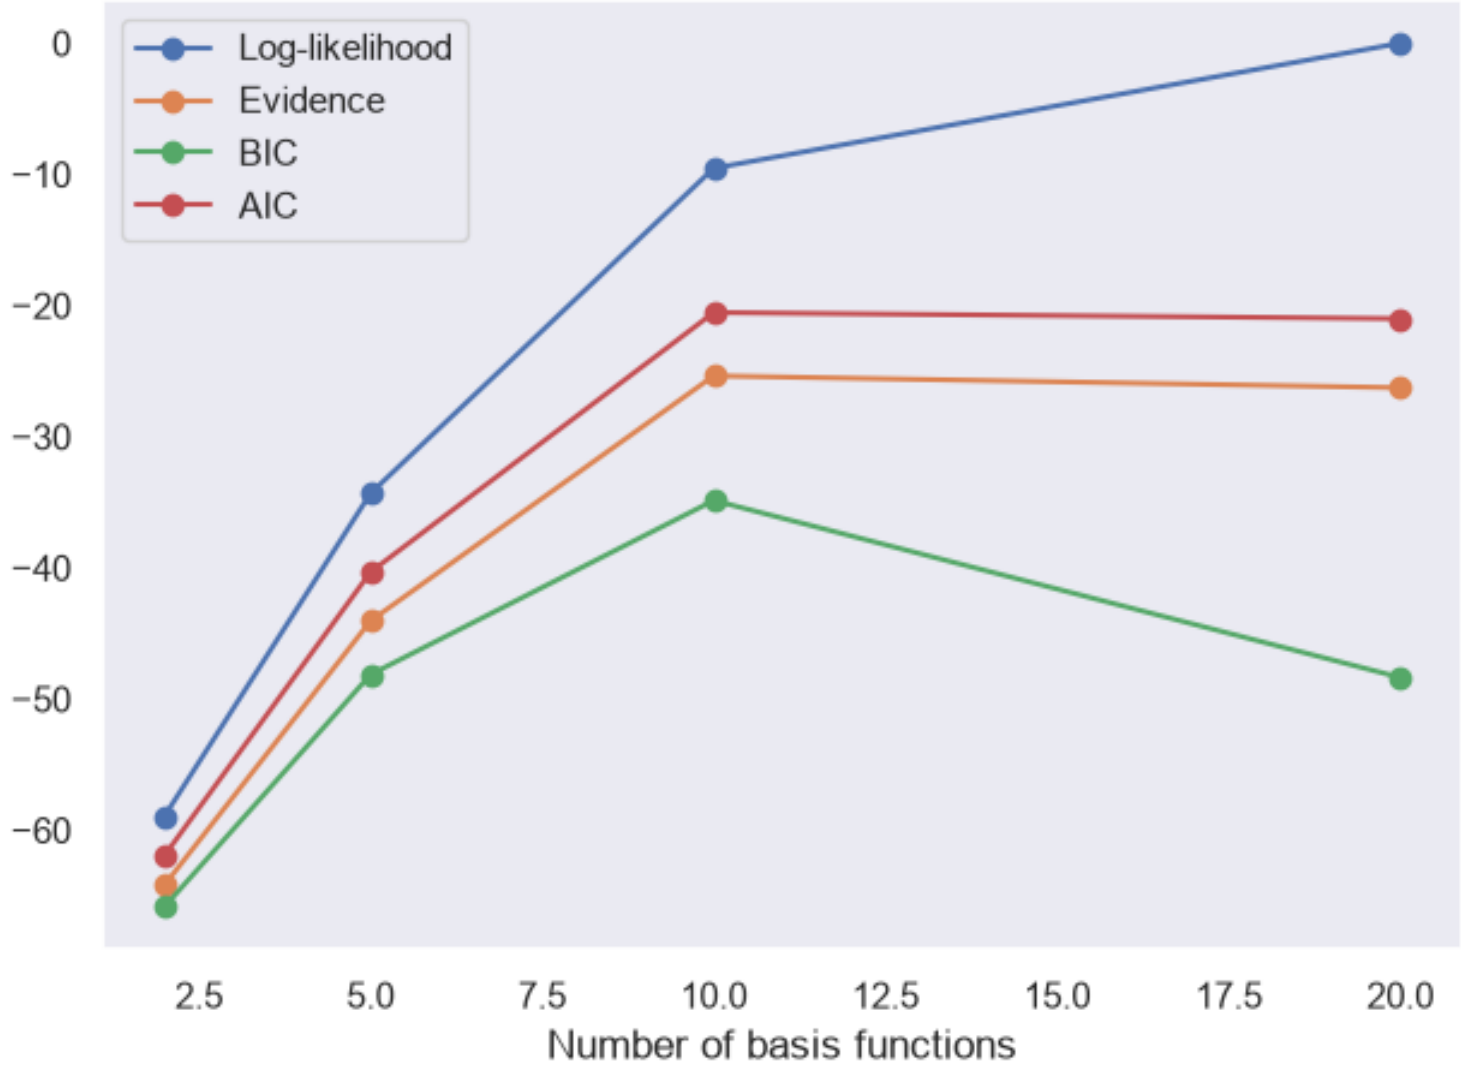


Regressão Logística RBF Bayesiana



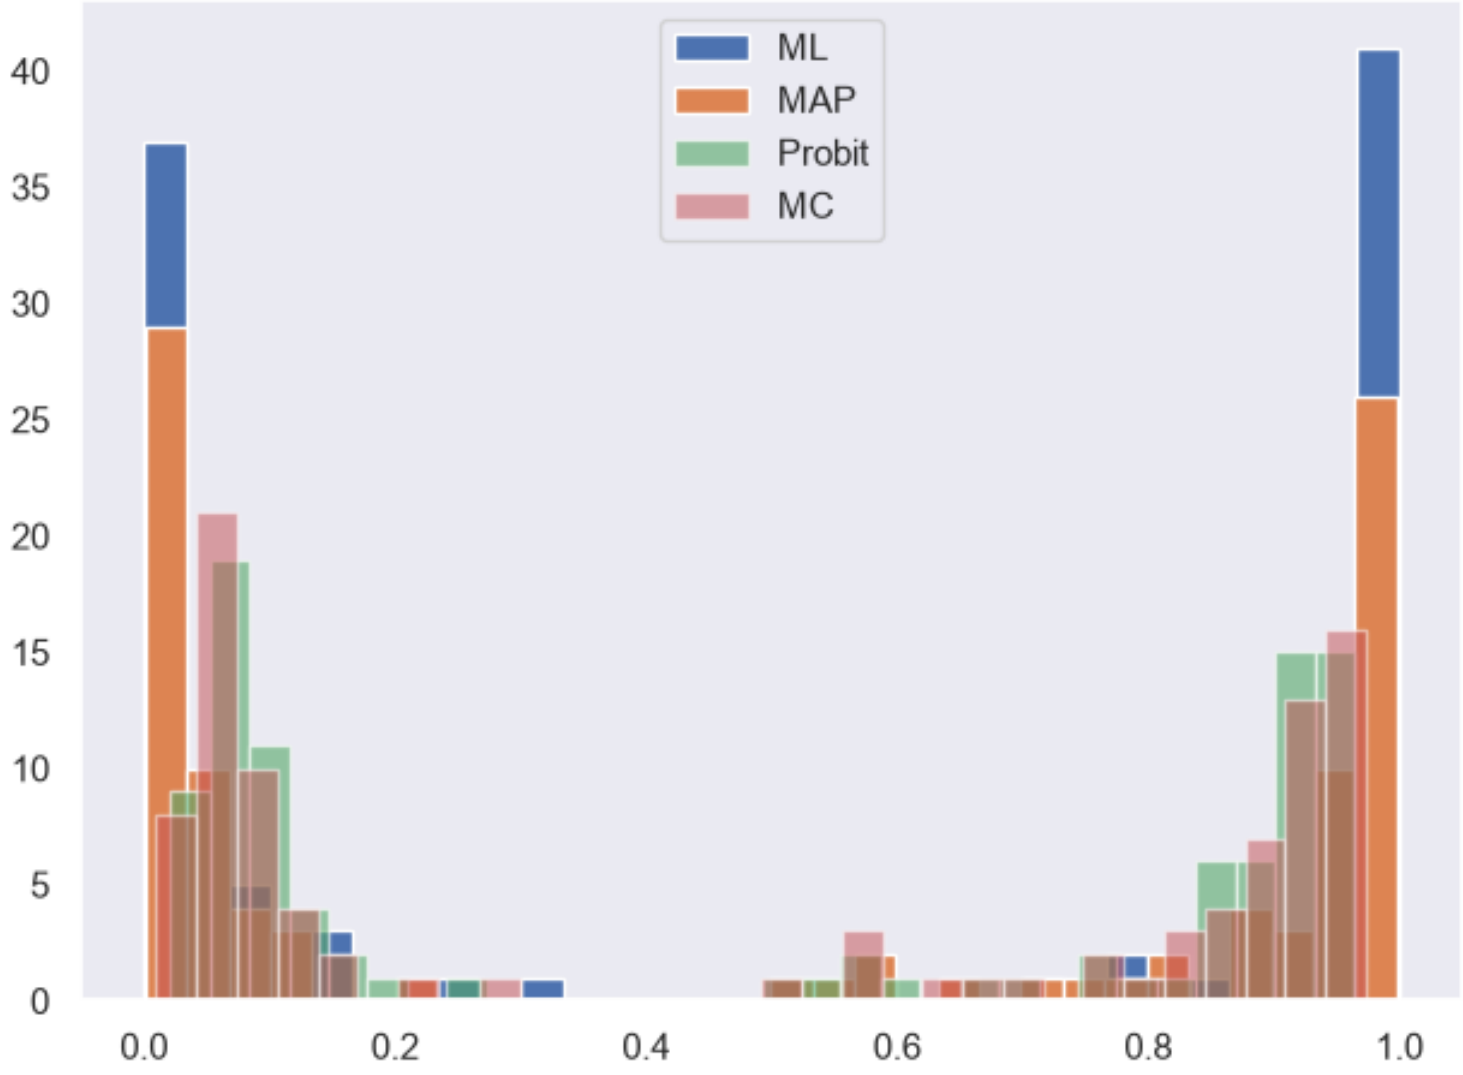
Regressão Logística RBF Bayesiana

Seleção de modelos



Regressão Logística RBF Bayesiana

Histograma de probabilidades



Regressão Logística RBF Bayesiana

Strip plot de probabilidades



Agenda

1. Classificação binária
2. Regressão logística binária
3. Regressão logística multiclasse
4. Regressão logística via algoritmo IRLS
5. Regressão logística Bayesiana - Aproximação de Laplace
6. Tópicos adicionais
7. Referências

Tópicos adicionais

- Representação de atributos categóricos via one hot encoding.
  - $\rightarrow$ **Exemplo**: Atributo "gênero de filme" (ação, drama ou comédia): $\mathbf{x}_i = [1\ 0\ 0]^\top$, ou $\mathbf{x}_i = [0\ 1\ 0]^\top$, ou $\mathbf{x}_i = [0\ 0\ 1]^\top$.
- Generalized linear models (GLMs).
- Regressão ordinal.

Agenda

1. Classificação binária
2. Regressão logística binária
3. Regressão logística multiclasse
4. Regressão logística via algoritmo IRLS
5. Regressão logística Bayesiana - Aproximação de Laplace
6. Tópicos adicionais
7. Referências

Referências bibliográficas

- **Cap. 8** - MURPHY, Kevin P. **Machine learning: a probabilistic perspective**, 2012.
- **Cap. 4** - BISHOP, Christopher M. **Pattern recognition and machine learning**, 2006.